RABIT : Jurnal Teknologi dan Sistem Informasi Univrab
Volume 11 No. 1 | Januari 2026 : Hal : 349-362
ISSN CETAK : 2477-2062
ISSN ONLINE : 2502-891X

ANALISIS SENTIMEN ULASAN APLIKASI MOBILE JKN MENGGUNAKAN NAÏVE BAYES, KNN, DAN SVM BERBASIS SMOTE

[1)]Octa Dwiansyah, [2)] Rizka Dhini Kurnia
[1,2)]Sistem Informasi, Fakultas Ilmu Komputer, Universitas Sriwijaya
[1,2)]Jl. Raya Palembang - Prabumulih No.KM. 32, Indralaya Indah, Kec. Indralaya, Kabupaten Ogan Ilir, Sumatera Selatan-Indonesia
E-mail : octadwiansyah@gmail.com, Rizkadhini@gmail.com

ABSTRAK
Analisis sentimen pada ulasan pengguna Mobile JKN berperan penting dalam mengidentifikasi tingkat kepuasan dan hambatan pengguna terhadap layanan digital BPJS Kesehatan. Penelitian ini bertujuan untuk mengevaluasi kinerja tiga algoritma klasifikasi Naïve Bayes, KNN, dan SVM yang dioptimalkan menggunakan SMOTE sebagai upaya menangani ketidakseimbangan data dalam proses analisis sentimen. Penelitian ini menggunakan 19.186 data ulasan yang telah melalui tahapan *preprocessing*, pembobotan TF-IDF dan *Split data* yang dibagi mengunakan skema 80:20 yaitu 15.348 data latih dan 3.838 data uji, kemudian diuji sebelum dan sesudah penerapan SMOTE untuk menilai pengaruh penyeimbangan data terhadap kinerja model. Hasil penelitian menunjukkan bahwa penerapan SMOTE mampu meningkatkan sensitivitas model terhadap kelas minoritas tanpa menurunkan akurasi secara signifikan. Model Naïve Bayes memiliki akurasi 93,56 % sebelum SMOTE dan 92,05 % sesudahnya, KNN meningkat dari 71,20 % menjadi 87,96 %, sedangkan SVM mempertahankan performa tertinggi dengan akurasi 93 % dan *F1-score* 0,91–0,95. Nilai AUC tertinggi diperoleh oleh SVM (0,98) diikuti Naïve Bayes (0,97) dan KNN (0,93). Hasil analisis menunjukkan bahwa mayoritas ulasan pengguna bersifat positif, mencerminkan kepuasan yang tinggi terhadap layanan Mobile JKN, sementara ulasan negatif umumnya berkaitan dengan kendala teknis. Secara keseluruhan, SVM berbasis SMOTE dinyatakan sebagai model paling efektif dalam analisis sentimen dan dapat menjadi dasar pengembangan evaluasi kualitas layanan digital BPJS Kesehatan.

Kata Kunci: Analisis Sentimen, Mobile Jkn, Naïve Bayes , K-Nearest Neighbor, Support Vector Machine

ABSTRACT
Sentiment analysis of user reviews on the Mobile JKN application plays an important role in identifying user satisfaction levels and obstacles encountered when accessing BPJS Kesehatan's digital services. This study aims to evaluate the performance of three classification algorithms Naïve Bayes, KNN, and SVM optimized using the SMOTE approach to address data imbalance. A total of 19,186 user reviews were used, which underwent preprocessing, TF-IDF weighting, and an 80:20 data split, resulting in 15,348 training data and 3,838 testing data. Each model was evaluated before and after SMOTE application to assess its impact on model performance. The results show that SMOTE improved model sensitivity toward minority classes without significantly reducing accuracy. The Naïve Bayes model achieved 93.56 % accuracy before SMOTE and 92.05 % after, KNN improved from 71.20 % to 87.96 %, while SVM maintained the highest performance with 93 % accuracy and an F1-score of 0.91–0.95. The highest AUC value was obtained by SVM (0.98), followed by Naïve Bayes (0.97) and KNN (0.93). Sentiment classification results revealed that most user reviews were positive, reflecting high satisfaction with the Mobile JKN service, while negative reviews were primarily related to technical issues. Overall, the SMOTE-based SVM model proved to be the most effective algorithm for sentiment analysis and can serve as a foundation for evaluating and improving the quality of BPJS Kesehatan's digital services.

Keyword: *Sentiment Analysis, Mobile JKN, Naïve Bayes, K-Nearest Neighbor, Support Vector Machine.*

PENDAHULUAN

Perkembangan teknologi informasi telah mengubah berbagai aspek kehidupan manusia, termasuk dalam bidang layanan public dan Kesehatan. Pemanfaatan teknologi digital memungkinkan Masyarakat untuk memberikan opini dan evaluasi terhadap layanan publik melalui platform daring seperti Google Play Store, yang menjadi salah satu sumber data penting dalam memahami persepsi dan tingkat kepuasan pengguna terhadap aplikasi tertentu. Salah satu layanan digital yang berperan penting di Indonesia adalah aplikasi Mobile

DOI : https://doi.org/10.36341/rabit.v11i1.6930
Some rights reserved BY-NC-SA 4.0 International License

JKN yang dikembangkan oleh BPJS Kesehatan, bertujuan untuk mempermudah akses terhadap layanan Jaminan Kesehatan Nasional (JKN) secara daring [1].

Namun, berbagai ulasan pengguna menunjukkan adanya keluhan terkait kinerja, stabilitas, dan fitur aplikasi. Kondisi ini menandakan adanya kesenjangan antara tujuan awal pengembangan aplikasi dengan pengalaman nyata pengguna. Analisis semacam ini menjadi penting untuk mendukung peningkatan kualitas layanan digital di sektor public, terutama di bidang Kesehatan.

Analisis sentimen merupakan suatu metodologi dalam ranah NLP yang difungsikan untuk mengekstraksi muatan emosional dan opini dalam teks, serta mengkategorikan hasilnya berdasarkan polaritas sentimen seperti positif dan negative. [2]. Pendekatan berbasis *machine learning* seperti *Naïve Bayes*, KNN, dan SVM telah terbuktik efektif dalam berbagai studi analisis sentimen [3]. Efektivitas masing-masing algoritma dapat bervariasi tergantung pada sifat data yang digunakan dan lingkungan atau domain tempat algoritma tersebut diterapkan.

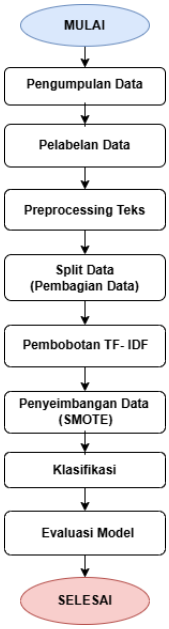
Beberapa penelitian terdahulu menunjukkan hasil yang bervariasi. Misalnya, penelitian yang dilakukan pada analisis sentimen popularitas calon presiden di twitter menemukan bahwa *Naïve Bayes* memiliki akurasi tertinggi mengungguli KNN dan SVM [4]. Sementara itu, dalam penelitian terhadap ulasan aplikasi Halodoc menunjukan bahwa KNN memberikan akurasi tertinggi dibandingkan dengan algoritma lain. perbedaan performa ini memperkuat pandangan bahwa efektivitas suatu algoritma tidak bersifat universal, tetapi sangat dipengaruhi oleh karakteristik domain, distribusi data, dan keseimbangan kelas sentimen [5].

Salah satu problematika yang kerap muncul dalam analisis sentimen adalah ketidakseimbangan kelas (*class imbalance*), yaitu kondisi Ketimpangan antara jumlah ulasan positif dan negatif dapat menimbulkan bias klasifikasi, di mana model cenderung mengutamakan prediksi pada kelas yang dominan, sehingga akurasi terhadap kelas dengan jumlah data lebih sedikit menjadi menurun. [6]. Masalah ketidakseimbangan data diatasi dengan pendekatan SMOTE, yang bekerja dengan menghasilkan data sintetis pada kelas minoritas guna meningkatkan keseimbangan distribusi data dalam proses pelatihan model. [7]. Pendekatan ini terbukti mampu meningkatkan performa model dalam berbagai penelitian analisis sentimen, termasuk pada domain aplikasi publik dan media sosial [8].

Berdasarkan tinjauan literatur, Kajian yang membahas evaluasi performa Naïve Bayes, KNN, dan SVM dengan integrasi SMOTE dalam konteks aplikasi layanan kesehatan digital seperti Mobile JKN masih terbatas dalam literatur penelitian. Berdasarkan hal tersebut, penelitian ini diarahkan untuk mengkaji performa tiga algoritma klasifikasi, yaitu Naïve Bayes, K-Nearest Neighbor, dan Support Vector Machine, dalam menganalisis sentimen ulasan pengguna aplikasi Mobile JKN. Penelitian ini juga bertujuan mengevaluasi pengaruh penerapan *Synthetic Minority Over-sampling Technique* (SMOTE) dalam meningkatkan kemampuan model pada kondisi ketidakseimbangan kelas, serta mengidentifikasi pola sentimen yang muncul dari ulasan pengguna sebagai gambaran persepsi masyarakat terhadap kualitas layanan aplikasi Mobile JKN. Temuan penelitian ini diharapkan dapat menjadi dasar empiris dalam upaya peningkatan kualitas layanan digital BPJS Kesehatan sekaligus memperluas kajian implementasi pembelajaran mesin untuk analisis sentimen berbahasa Indonesia.

DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

METODE



Gambar 1. Alur Metode

Penelitian ini menggunakan pendekatan kuantitatif dengan desain eksperimental untuk mengevaluasi kapabilitas Tiga algoritma, yakni *Naïve Bayes, K-Nearest Neighbor,* dan *Support Vector Machine*, digunakan sebagai model klasifikasi guna mengelompokkan data sentimen secara otomatis pada sentimen ulasan pengguna platform Mobile JKN. Seluruh proses eksperimen dilakukan menggunakan Google Colab karena platform ini mendukung eksekusi berbasis Python dan pengolahan data berskala besar. Alur penelitian dilaksanakan secara terstruktur, mencakup tahapan pengumpulan dan pelabelan dataset, pra-pemrosesan teks, pembagian dataset, transformasi bobot TF-IDF, penyeimbangan kelas melalui SMOTE, hingga klasifikasi dan evaluasi model untuk memperoleh hasil analisis yang optimal.

Pengumpulan Data

Sumber dataset penelitian berasal dari ulasan pengguna aplikasi Mobile JKN yang diperoleh melalui metode web scraping pada Google Play Store, memanfaatkan library google-play-scraper untuk ekstraksi data secara otomatis dan terstruktur. Ulasan yang dikumpulkan mencakup tiga atribut utama, yaitu username pengguna, rating aplikasi dengan skala 1-5, serta teks ulasan dalam bahasa Indonesia. Volume data yang digunakan dalam penelitian ini mencapai sekitar 20.000 ulasan atau data, sehingga diharapkan mampu merepresentasikan opini dan persepsi pengguna aplikasi Mobile JKN secara lebih luas dan komprehensif.

Pelabelan Data

Label sentimen dalam penelitian ini ditentukan berdasarkan rating bintang yang diberikan pengguna pada aplikasi Mobile JKN, yaitu positif jika rating ≥ 4 dan negatif jika rating ≤ 3. Kategori netral tidak digunakan karena dapat memperburuk kondisi ketidakseimbangan data yang sudah ada pada distribusi ulasan. Dengan membatasi klasifikasi pada dua kategori utama positif dan negatif proses penyeimbangan data SMOTE dapat dilakukan secara lebih efektif sehingga model klasifikasi yang dibangun mampu menghasilkan performa yang stabil.

Preprocessing Data

Sebelum data ulasan diproses, diperlukan tahap preprocessing untuk membersihkan teks dari elemen yang tidak relevan. Preprocessing ini penting dilakukan agar representasi teks menjadi lebih terstruktur, mudah dibobotkan, dan menghasilkan performa klasifikasi yang lebih baik [9]. Adapun langkah-langkah yang diterapkan:

a. *Case folding,* merupakan proses mengubah seluruh huruf menjadi huruf kecil. Tujuannya adalah menyeragamkan kata agar tidak dianggap berbeda hanya karena perbedaan kapitalisasi, misalnya kata "*Aplikasi"* dan "*aplikasi* [10].
b. *Cleaning,* dilakukan untuk menghapus angka, tanda baca, simbol, URL, dan

DOI : https://doi.org/10.36341/rabit.v11i1.6930
Corresponding Author : Octa Dwiansyah

emotikon. Tahap ini bertujuan mengurangi *noise* sehingga hanya informasi penting yang dipertahankan [11].

c. *Stopword Removal*, Penghapusan kata-kata yang frekuensi kemunculannya tinggi namun memiliki nilai informatif rendah, seperti "dan", "di", atau "yang", untuk menurunkan dimensi data dan meningkatkan efisiensi komputasi [12].

d. Stemming, Transformasi kata berimbuhan ke bentuk dasarnya, misalnya "bermain" menjadi "main", sehingga beragam bentuk kata yang memiliki akar leksikal sama dapat disatukan dalam representasi yang konsisten, sehingga mempermudah proses pembobotan dan analisis kata [13].

e. Tokenisasi, merupakan proses memecah teks ulasan menjadi unit terkecil berupa kata. Misalnya, kalimat *"Aplikasinya bagus sekali"* diubah menjadi token ["aplikasi", "bagus", "sekali"]. Proses ini penting agar algoritma pembobotan seperti TF-IDF dapat menghitung frekuensi tiap kata [8].

Split Data

Pembagian dataset dilakukan menggunakan skema 80:20, di mana sebagian besar data (80%) dimanfaatkan untuk melatih model, sedangkan sisanya (20%) digunakan sebagai data uji guna mengevaluasi tingkat akurasi dan generalisasi model. [14].

Pembobotan TF-IDF

Sebelum model klasifikasi diterapkan, teks ulasan perlu direpresentasikan dalam bentuk numerik agar dapat dipahami oleh algoritma. Teknik yang umum digunakan adalah TF-IDF, yang membobot kata berdasarkan frekuensinya dalam dokumen dan invers dari sebarannya dalam korpus [2].

Penyeimbangan Data (SMOTE)

Ketidakseimbangan kelas yang dimana positif jauh lebih banyak dari pada negatif atau ketimpangan data dapat menyebabkan model bias ke kelas mayoritas. Untuk mengatasinya, digunakan SMOTE yang menghasilkan data sintetis pada kelas minoritas melalui interpolasi [6].

Klasifikasi Model

Tahap ini berfokus pada pembangunan model klasifikasi berbasis machine learning untuk mendeteksi polaritas sentimen ulasan aplikasi Mobile JKN, mencakup kategori positif dan negatif. Tiga algoritma yang digunakan Naïve Bayes, KNN, dan SVM dipilih karena memiliki track record yang baik mengklasifikasikan model.

a. *Naïve Bayes*, Model *Naïve Bayes* yang digunakan dalam penelitian ini adalah varian *Multinomial Naïve Bayes (MultinomialNB)*, dengan parameter smoothing $\alpha = 1.0$ sesuai konfigurasi default Scikit-learn. Model ini dipilih karena dapat menangani representasi berbasis frekuensi secara efektif dan memiliki kinerja yang baik.

b. *K-Nearest Neighbor,* Algoritma *K-Nearest Neighbor* diimplementasikan menggunakan nilai $k = 5$ sebagai jumlah tetangga terdekat. Metrik jarak yang digunakan adalah Euclidean, yang merupakan pengaturan default Scikit-learn melalui parameter *metric='minkowski'* dengan nilai $p = 2$. Konfigurasi ini dipilih karena memberikan stabilitas yang baik dalam proses klasifikasi pada data berdimensi tinggi.

c. *Support Vector Machine,* Model Support Vector Machine pada penelitian ini menggunakan

DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

LinearSVC, yaitu implementasi SVM berbasis kernel linear. Parameter regularisasi ditetapkan pada nilai C = 1.0, sesuai konfigurasi standar untuk pengujian baseline. LinearSVC dipilih karena efisien dalam menangani vektor fitur berukuran besar dan tidak membutuhkan parameter gamma, mengingat model ini menggunakan kernel linear.

Evaluasi Model

Tahap evaluasi model bertujuan untuk mengukur kinerja sistem dalam melakukan proses klasifikasi secara tepat dan konsisten. Evaluasi mencakup pengukuran akurasi, presisi, recall, dan F1-score guna menilai efektivitas model pada data dengan distribusi kelas yang tidak seimbang [15]. serta ROC-AUC yang digunakan untuk mengevaluasi kemampuan diskriminasi antar kelas. Pada penelitian ini digunakan pembagian data sebesar 80:20 dengan metode *stratified split* untuk menjaga proporsi kelas pada data latih dan data uji. Validasi silang (*cross-validation*) tidak diterapkan karena penelitian ini berfokus pada perbandingan performa model sebelum dan sesudah penerapan SMOTE, bukan pada proses tuning hyperparameter. Selain itu, ukuran dataset yang besar membuat penggunaan cross-validation berulang membutuhkan sumber daya komputasi yang tinggi, sehingga pendekatan split tunggal dianggap memadai dan relevan untuk desain eksperimen komparatif.

HASIL

Penelitian ini menyajikan hasil implementasi dan analisis dari setiap tahapan penelitian yang telah dijelaskan pada bagian metode penelitian. Seluruh proses penelitian ini dilakukan secara terstruktur menggunakan Google Colab sebagai platform utama pengolahan data dan implementasi model. Mulai dari pengumpulan data melalui teknik *scraping* pada aplikasi Mobil JKN, hingga tahap evaluasi model klasifikasi sentiment yang menggunakan tiga algoritma utama, yaitu *Naïve Bayes*, KNN, dan SVM yang ditingkatkan melalui penyeimbangan data dengan teknik SMOTE.

Pengumpulan Data

Dataset penelitian Dataset penelitian dihasilkan melalui metode pengambilan data otomatis (*web scraping*) menggunakan pustaka google-play-scraper pada aplikasi Mobile JKN, dengan objek kajian berupa aplikasi Mobile JKN milik BPJS Kesehatan. Proses ekstraksi data dilakukan secara otomatis untuk memperoleh ulasan pengguna yang merepresentasikan pengalaman dan persepsi masyarakat terhadap kinerja aplikasi. Data yang terkumpul meliputi identitas pengguna, rating bintang (skala 1-5), dan konten ulasan dalam bahasa Indonesia, dengan total 20.000 ulasan yang tersimpan dalam format CSV, yang digunakan sebagai dataset utama dalam penelitian ini.

Tabel 1. Contoh hasil *Scraping* ulasan aplikasi

Username	Rating	Komentar
Handrianto prahba	5	Aplikasi mudah digunakan dan pelayanan petugas ramah dan baik
Lidia Julia	5	Pelayanan memuaskan
Bondan Prasetio	1	Mau bayar saja ribet pakai auto debit segala apk sering bermasalah pemilihan non bank saja sedikit sekali

Pelabelan Data

Tahap pelabelan data yang merupakan proses penting untuk menentukan setiap ulasan pengguna ke dalam kategori positif dan negatif berdasarkan rating bintang pada *Google Play Store*. Penentuan label dilakukan secara

DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

otomatis menggunakan logika berbasis nilai rating yang dimana positif jika rating ≥ 4 dan negatif jika rating ≤ 3. Pendekatan berbasis *rating score* ini dipilih karena penilaian bintang umumnya berkolerasi langsung dengan ekspresi sentiment pengguna. Rating tinggi (4-5) menunjukkan pengalaman positif terhadap aplikasi Mobile JKN, sedangkan rating rendah (1-3) menunjukkan adanya ketidakpuasan atau kendala dalam penggunaan aplikasi. Pada tahap pelabelan ini tidak menambahkan kategori netral dikarenakan sering kali bersifat ambigu dan tidak menunjukkan apakah positif atau negative sehingga dapa meningkatkan efektivitas penggunaan teknik SMOTE.

Tabel 2. Contoh hasil Pelabelan Data

Rating	Komentar	Label Sentimen
5	Aplikasi mudah digunakan dan pelayanan petugas ramah dan baik	Positif
5	Pelayanan memuaskan	Positif
1	Mau bayar saja ribet pakai auto debit segala apk sering bermasalah pemilihan non bank saja sedikit sekali	Negatif

Preprocessing Data

Tahap preprocessing dilakukan untuk menyiapkan teks ulasan agar dapat diolah secara optimal oleh algoritma machine learning. Proses ini dijalankan di Google Colab yang mendukung eksekusi Python serta pustaka NLP seperti Sastrawi dan Scikit-learn. Langkah-langkahnya meliputi case folding untuk menyeragamkan huruf, cleaning guna menghapus angka, tanda baca, dan tautan, Tahapan stopword removal bertujuan untuk mengeliminasi kata-kata seperti “dan” atau “yang”, yang tidak memberikan kontribusi signifikan terhadap pemahaman konteks teks., stemming dengan Sastrawi agar kata kembali ke bentuk dasarnya, serta tokenizing untuk memecah teks menjadi kata terpisah sebelum pembobotan TF-IDF. Hasil dari tahap ini berupa teks yang bersih, konsisten, dan siap dikonversi ke bentuk numerik. Dari total sekitar 20.000 ulasan yang dikumpulkan, sebanyak 19.186 data valid digunakan untuk pelatihan dan pengujian model analisis sentimen.

Tabel 3. Contoh hasil *preprocessing data*

Komentar	*Cleaned_comments*	*Tokenizing*
Aplikasi mudah digunakan dan pelayanan petugas ramah dan baik	aplikasi mudah guna layan tugas ramah baik	['aplikasi', 'mudah', '', 'guna', '', 'layan', 'tugas', 'ramah', '', 'baik']
Pelayanan memuaskan	layan muas	['layan', 'muas']
Mau bayar saja ribet pakai auto debit segala apk sering bermasalah pemilihan non bank saja sedikit sekali	mau bayar aja ribet pake auto debit segala apk sering masalah pilih non bank sedikit sekali	['mau', 'bayar', 'aja', 'ribet', 'pake', 'auto', 'debit', 'segala', 'apk', 'sering', 'masalah', 'pilih', 'non', 'bank', '', 'sedikit', 'sekali']

Split Data

Dataset sebanyak 19.186 ulasan dibagi dengan rasio 80:20, menghasilkan 15.348 data pelatihan dan 3.838 data pengujian. Parameter stratify digunakan untuk memastikan distribusi kelas tetap proporsional di kedua subset.

Pembobotan TF-IDF

Pada tahap pembobotan TF-IDF, teks hasil preprocessing dikonversi menjadi representasi numerik agar dapat dikenali oleh algoritma machine learning. Metode TF-IDF digunakan untuk mengukur relevansi setiap kata Perhitungan bobot TF-IDF dilakukan menggunakan pustaka *scikit-learn* di Google Colab, dengan fungsi *TfidVectorizer()*. TF

DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

menggambarkan frekuensi kemunculan kata dalam dokumen tertentu, sedangkan IDF mengukur tingkat kelangkaannya di seluruh korpus. Gabungan keduanya menghasilkan bobot TF-IDF yang menonjol untuk kata dengan nilai informasi tinggi dan kemunculan terbatas.

Pada tabel 4 merupakan contoh dari pembobotan TF-IDF dari bobot yang tertinggi:

Tabel 4. Pembobotan TF-IDF

Index	*Term*	*TF*	*IDF*	*TF-IDF*
4346	sangat	0.08344	2.59514	0.08344
275	bantu	0.06952	2.93670	0.06952
237	bagus	0.06325	3.25854	0.06325
2768	mantap	0.04962	3.82097	0.04962
3186	mudah	0.04523	3.05963	0.04523

Setelah tahap pembobotan TF-IDF, dilakukan visualisasi distribusi frekuensi kata menggunakan *WordCloud* untuk menunjukkan gambaran umum mengenai beberapa kata dominan dalam ulasan pengguna aplikasi Mobile JKN. Tahapan visualisasi dilakukan melalui WordCloud yang menggambarkan perbedaan dominasi kata pada ulasan positif dan negatif. Representasi ini digunakan untuk memperkuat hasil pembobotan TF-IDF dengan tampilan yang lebih mudah dipahami, serta memberikan gambaran awal mengenai pola leksikal data sebelum penerapan SMOTE dan proses klasifikasi.





Gambar 2. *Wordcloud* positif dan negatif

Penyeimbangan Data (SMOTE)

Penyeimbangan data menggunakan pendekatan SMOTE (*Synthentic Minority Over-sampling Technique*) untuk mengatasi permasalahan ketidakseimbangan data (*imbalance data*) antara kelas positif dan negatif. Dalam dataset ulasan aplikasi Mobile JKN, yang dimana jumlah ulasan positif lebih besar dibandingkan ulasan negatif. Untuk mengatasi hal ini digunakan teknik SMOTE, yang bekerja dengan menghasilkan sampel sintetis baru untuk kelas minoritas berdasarkan interpolasi antara titik-titik terdekat dalam ruang fitur TF-IDF. Hasil penerapan SMOTE pada penelitian ini menunjukkan distribusi kelas menjadi seimbang yang dari semula 9.639 ulasan positif dan 5.709 ulasan negatif pada data latih menjadi masing-masing 9.639 ulasan untuk setiap kelas. Dengan data yang lebih seimbang, proses pelatihan model menjadi lebih stabil dan akurasi antar kelas meningkat secara signifikan.

Tabel 5. Hasil SMOTE

Sebelum SMOTE		Sesudah SMOTE	
Label	Jumlah	Label	Jumlah
Positif	9.639	Positif	9.639
Negatif	5.709	Negatif	9.639

Klasifikasi

Tahap klasifikasi dilakukan dengan menerapkan tiga algoritma, yaitu *Naïve Bayes*, KNN, dan SVM. Model dilatih menggunakan data hasil *preprocessing data* lalu dilanjutkan

DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

pembobotan TF-IDF dan melalui proses penyeimbangan kelas dengan metode SMOTE. Metode SMOTE ini dilakukan dengan perintah *smote.fit_resample(x_train_tfidf, y_train)* yang bertujuan memperbaiki distribusi kelas pada data latih. SMOTE diterapkan hanya pada latih karena berfungsi membantu model mempelajari pola dari kedua kelas secara seimbang yang tidak mengubah data uji secara langsung tetapi memengaruhi performa mode saat pengujian karena model telah dilatih dengan representasi data yang lebih seimbang.

Setelah proses penyeimbangan, model dilatih menggunakan fungsi *fit(x_train_tfidf, y_train)* untuk mempelajari hubungan antara fitur dan label sentiment, kemudian dilakukan prediksi terhadap data uji menggunakan *predict(x_test_tfidf)*. Model yang menghasilkan dua label sentiment yaitu positif dan negative, untuk setiap ulasan pengguna aplikasi Mobile JKN. Hasil prediksi tersebut menjadi dasar dalam tahap evaluasi performa model, yang dilakukan melalui pengukuran beberapa perhitungan untuk menilai sejauh mana penerapan SMOTE mampu meningkatkan efektivitas model dalam melakukan klasifikasi sentimen

Evaluasi Model

1. *Naïve bayes (NB)*

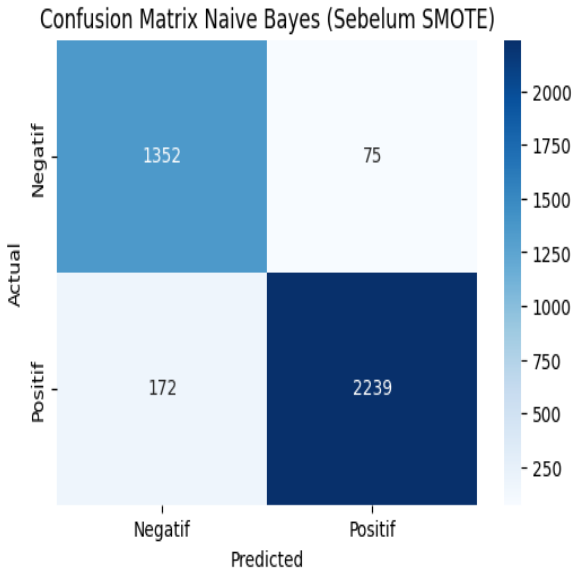
Pada tahap evaluasi, algoritma *Naïve Bayes* diuji untuk membandingkan performa model sebelum dan sesudah penerapan metode SMOTE. Sebelum dilakukan penyeimbangan data, model Akurasi 93,56% sebelum SMOTE dan 92,05% setelahnya. Recall kelas negatif meningkat dari 0,95 menjadi 0,97, menunjukkan model lebih sensitif terhadap kelas minoritas. Yang dapat dilihat pada Gambar 3. Hasil evaluasi sebelum SMOTE

```
=== Hasil Sebelum SMOTE ===
Akurasi : 0.9356435643564357

Classification Report:
              precision    recall  f1-score   support

     Negatif       0.89      0.95      0.92      1427
     Positif       0.97      0.93      0.95      2411

    accuracy                           0.94      3838
   macro avg       0.93      0.94      0.93      3838
weighted avg       0.94      0.94      0.94      3838
```



Gambar 3. Hasil sebelum SMOTE NB

Setelah dilakukan SMOTE pada data latih, akurasi model menjadi 92,05 %. Meskipun akurasi menurun sedikit, nilai *recall* kelas negatif meningkat (dari 0,95 menjadi 0,97), menandakan model menjadi lebih sensitif terhadap kelas minoritas. Peningkatan ini menunjukkan bahwa SMOTE berhasil membantu model mengenali pola data negatif yang sebelumnya kurang terwakili. Berikut hasil sesudah SMOTE

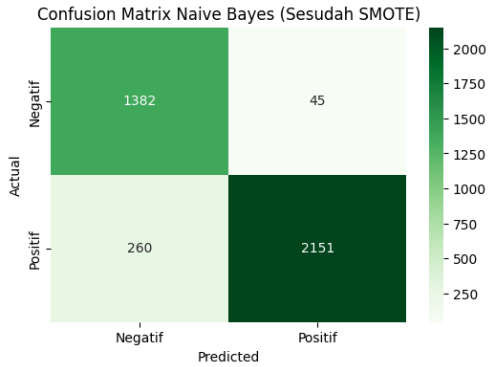
DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

```
=== Hasil Sesudah SMOTE ===
Akurasi : 0.9205315268368942

Classification Report:
              precision    recall  f1-score   support

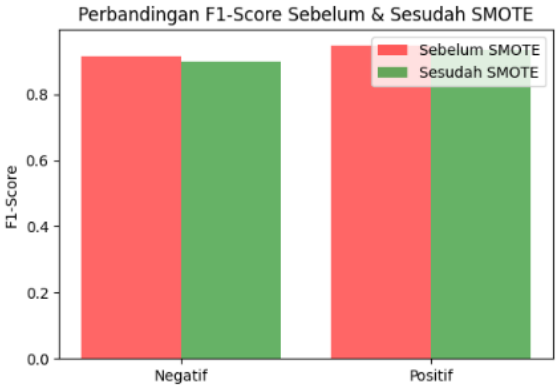
     Negatif       0.84      0.97      0.90      1427
     Positif       0.98      0.89      0.93      2411

    accuracy                           0.92      3838
   macro avg       0.91      0.93      0.92      3838
weighted avg       0.93      0.92      0.92      3838
```



Gambar 4. Hasil sesudah SMOTE NB

Perbandingan nilai F1-score sebelum dan sesudah SMOTE memperlihatkan keseimbangan performa antara kedua kelas. Metrik ini dipilih sebagai tolok ukur utama karena F1-score menggabungkan *precision* dan *recall* secara proporsional, sehingga lebih representatif untuk menilai kinerja model pada data yang awalnya tidak seimbang. Dengan demikian, meskipun akurasi sedikit menurun, penerapan SMOTE menghasilkan model yang lebih adil dalam mengklasifikasikan kedua kelas sentimen. Berikut perbandingan *F1-score* sebelum dan sesudah SMOTE



Gambar 5. Perbandingan Sebelum dan sesudah SMOTE NB

2. K-Nearest Neighbor

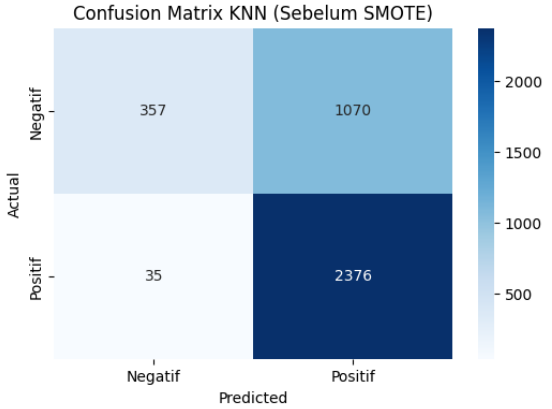
Model KNN sebelum penerapan SMOTE menghasilkan akurasi 71,20 %, dengan *recall* rendah pada kelas negatif (0,25) dan sangat tinggi pada kelas positif (0,99), menandakan bias terhadap kelas mayoritas.

```
=== KNN (Sebelum SMOTE) ===
Akurasi: 0.7120896300156332

Classification Report:
              precision    recall  f1-score   support

     Negatif       0.91      0.25      0.39      1427
     Positif       0.69      0.99      0.81      2411

    accuracy                           0.71      3838
   macro avg       0.80      0.62      0.60      3838
weighted avg       0.77      0.71      0.66      3838
```



Gambar 6. Hasil sebelum SMOTE KNN

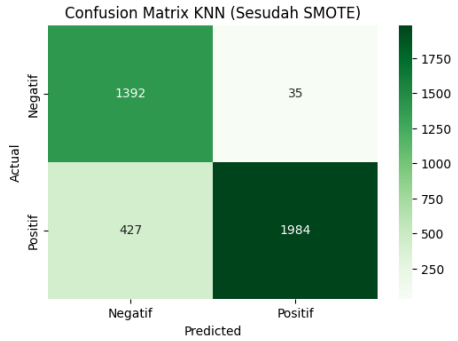
Setelah dilakukan penyeimbangan data menggunakan SMOTE, akurasi meningkat menjadi 87,96 %, dan *recall* kelas negatif naik signifikan menjadi 0,98, menunjukkan model lebih seimbang dalam mengenali kedua kelas sentimen. Seperti pada gambar 7:

```
=== KNN (Sesudah SMOTE) ===
Akurasi: 0.8796248045857217

Classification Report:
              precision    recall  f1-score   support

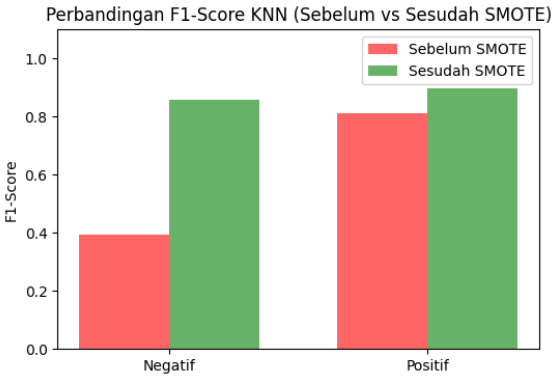
     Negatif       0.77      0.98      0.86      1427
     Positif       0.98      0.82      0.90      2411

    accuracy                           0.88      3838
   macro avg       0.87      0.90      0.88      3838
weighted avg       0.90      0.88      0.88      3838
```



Gambar 7. Hasil sesudah SMOTE KNN

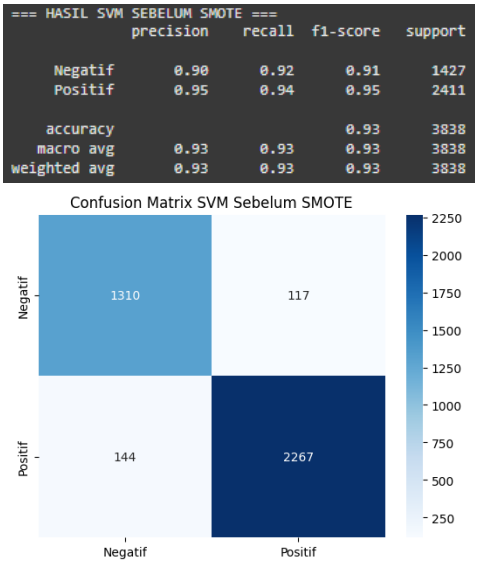
Peningkatan juga terlihat pada nilai *F1-score*, khususnya kelas negatif yang naik dari 0,39 menjadi 0,86. Peningkatan kinerja KNN setelah penerapan SMOTE terjadi karena algoritma ini sangat bergantung pada distribusi tetangga terdekat di ruang fitur. Pada data tidak seimbang, kelas mayoritas mendominasi proses voting sehingga prediksi menjadi bias. SMOTE membuat distribusi kelas lebih merata, sehingga kelas minoritas lebih sering terpilih sebagai tetangga terdekat dan menyebabkan peningkatan signifikan pada recall dan F1-score KNN..



Gambar 8. Perbandingan sebelum dan sesudah SMOTE KNN

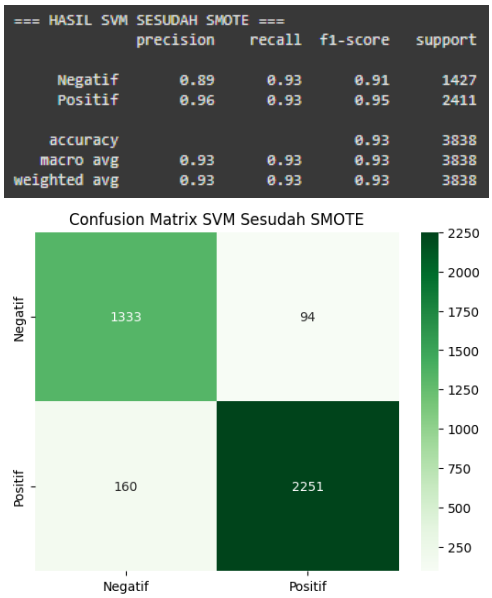
3. *Support Vector Machine*

Algoritma SVM menunjukkan performa yang relatif stabil baik sebelum maupun sesudah penerapan metode SMOTE. Sebelum SMOTE, model memperoleh akurasi 93,46 % dengan *F1-score* masing-masing 0,91 untuk kelas negatif dan 0,95 untuk kelas positif. Yang bisa dilihat pada gambar 9:



Gambar 9. Hasil sebelum SMOTE SVM

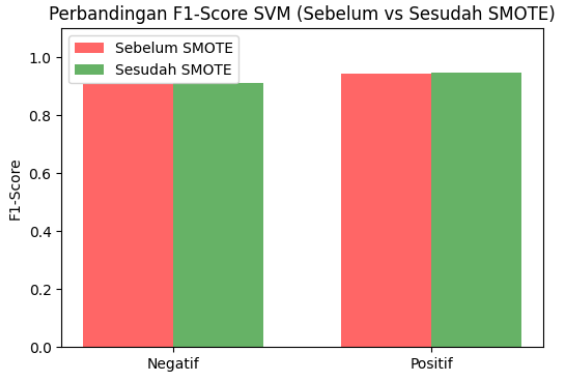
Setelah dilakukan penyeimbangan data, akurasi sedikit menurun menjadi 93,03 %, namun *recall* kelas negatif meningkat dari 0,92 menjadi 0,93. Hal ini menunjukkan bahwa penerapan SMOTE membuat model sedikit lebih sensitif dalam mengenali kelas minoritas tanpa mengubah keseimbangan performa secara signifikan.



Gambar 10. Hasil sesudah SMOTE SVM

Secara keseluruhan, *F1-score* kedua kelas

tetap stabil di kisaran 0,91–0,95, yang menandakan model SVM mampu mempertahankan konsistensi kinerjanya setelah penyeimbangan data. F1-score digunakan sebagai metrik utama karena mampu menggambarkan keseimbangan antara precision dan recall, serta menyediakan evaluasi yang lebih representatif terhadap kinerja model pada data yang tidak seimbang.



Gambar 11. Perbandingan sebelum dan sesudah SMOTE SVM

4. Tabel ringkasan kinerja model

Tabel 6. Tabel Ringkasan Kinerja Model

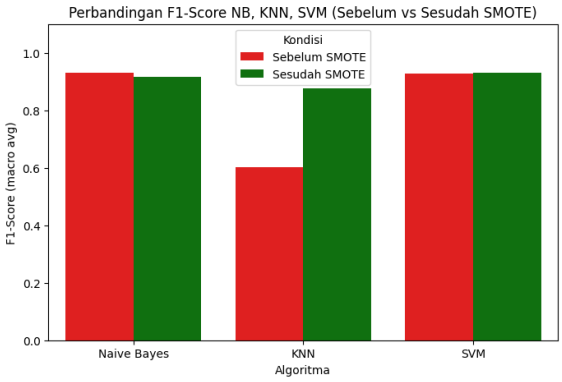
Model	*SMOTE*	*Accuracy*	*Precision*	*Recall*	*F1-Score*
Naive Bayes	Sebelum	0.936	0.93	0.94	0.93
Naive Bayes	**Sesudah**	**0.921**	**0.91**	**0.93**	**0.92**
KNN	Sebelum	0.712	0.80	0.62	0.60
KNN	**Sesudah**	**0.880**	**0.87**	**0.90**	**0.88**
SVM	Sebelum	0.930	0.93	0.93	0.93
SVM	**Sesudah**	**0.930**	**0.93**	**0.93**	**0.93**

Berdasarkan tabel ringkasan, penerapan SMOTE menunjukkan pengaruh yang berbeda pada setiap algoritma. Naïve Bayes dan SVM cenderung stabil, dengan perubahan akurasi dan F1-score yang relatif kecil setelah penyeimbangan data. Sebaliknya, KNN mengalami peningkatan kinerja yang signifikan, terutama pada recall dan F1-score kelas negatif. Hal ini menunjukkan bahwa KNN lebih sensitif terhadap ketidakseimbangan data, sehingga penerapan SMOTE memberikan dampak yang lebih besar dibandingkan kedua model lainnya.

5. Perbandingan *F1-score* antar Algoritma

Secara keseluruhan, penerapan SMOTE meningkatkan keseimbangan performa model, terutama pada algoritma KNN yang sebelumnya menunjukkan nilai F1-score lebih rendah akibat dominasi kelas positif. Setelah penyeimbangan data, F1-score KNN meningkat signifikan hingga mendekati kinerja Naïve Bayes dan SVM. Sementara itu, Naïve Bayes dan SVM menunjukkan performa yang relatif stabil dengan perbedaan nilai F1-score yang kecil antara kondisi sebelum dan sesudah SMOTE. Hal ini menegaskan bahwa SMOTE efektif memperbaiki sensitivitas model terhadap kelas minoritas tanpa mengurangi akurasi keseluruhan.

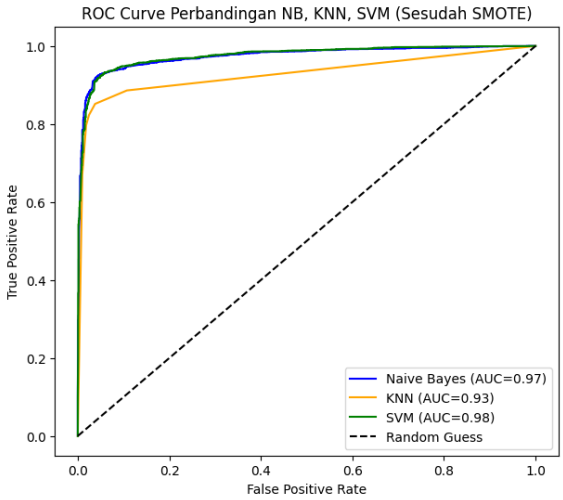
Pemilihan F1-score sebagai metrik utama didasarkan pada kemampuannya menilai keseimbangan antara precision dan recall, sehingga memberikan representasi yang lebih adil terhadap performa model pada dataset tidak seimbang. Berikut tampilan visual dari perbandingan f1-score dari ketiga algoritma:



Gambar 12. Perbandingan *f1-score* dari ketiga algoritma

6. Analisis *ROC-AUC Curve*

Selanjutnya yaitu analisis ROC-AUC Curve yang dimana, Nilai AUC tertinggi diperoleh oleh SVM (0,98), diikuti Naïve Bayes (0,97) dan KNN (0,93). Nilai AUC yang tinggi menunjukkan kemampuan model dalam membedakan kelas positif dan negatif secara konsisten. Pada gambar 13. memperlihatkan perbandingan kurva ROC dari ketiga algoritma:



Gambar 13. *ROC-AUC Curve*

Secara keseluruhan, SVM memiliki performa paling unggul, diikuti oleh Naïve Bayes, sementara KNN masih berada di bawah keduanya. Seluruh model berada jauh di atas garis *random guess*, yang menandakan ketiganya mampu melakukan klasifikasi lebih baik daripada tebakan acak.

Pembahasan

Secara keseluruhan, hasil penelitian menunjukkan bahwa penerapan SMOTE mampu meningkatkan keseimbangan performa model klasifikasi sentimen, terutama pada algoritma KNN yang sebelumnya memiliki tingkat akurasi rendah akibat dominasi kelas positif. Setelah penyeimbangan data, akurasi KNN meningkat secara signifikan dan mendekati kinerja Naïve Bayes dan SVM. Peningkatan ini terjadi karena KNN sangat bergantung pada distribusi tetangga terdekat di ruang fitur; pada kondisi data tidak seimbang, data latih dari kelas mayoritas lebih padat dan mendominasi proses voting, sehingga menurunkan akurasi klasifikasi. Penerapan SMOTE membuat distribusi kelas minoritas lebih merata, sehingga keputusan klasifikasi menjadi lebih seimbang dan akurasi model meningkat secara nyata.

Sementara itu, Naïve Bayes dan SVM menunjukkan performa yang relatif stabil dengan perbedaan akurasi yang kecil antara kondisi sebelum dan sesudah SMOTE. Meskipun terdapat sedikit penurunan akurasi setelah penyeimbangan data, kondisi ini mencerminkan adanya trade-off yang wajar antara akurasi keseluruhan dan peningkatan kemampuan model dalam mengenali kelas minoritas. Analisis confusion matrix menunjukkan bahwa jumlah kesalahan klasifikasi pada kelas minoritas berkurang setelah penerapan SMOTE, sehingga penurunan akurasi yang relatif kecil dapat diterima demi memperoleh keseimbangan dan keadilan klasifikasi pada dataset yang tidak seimbang.

SVM menunjukkan kinerja paling stabil dan unggul dengan tingkat akurasi yang konsisten, yang mengindikasikan bahwa representasi fitur berbasis TF-IDF pada ulasan Mobile JKN cenderung dapat dipisahkan secara linier dan sesuai dengan penggunaan kernel linear. Karakteristik ini membuat SVM lebih robust terhadap perubahan distribusi data akibat penerapan SMOTE. Dominasi ulasan positif dalam dataset turut mendukung konsistensi batas keputusan model. Hasil ini konsisten dengan penelitian sebelumnya pada analisis sentimen aplikasi layanan publik dan kesehatan yang melaporkan kinerja SVM dengan akurasi di atas 90%, bahkan mencapai sekitar 95% [5]. Adapun keterbatasan penelitian ini terletak pada pelabelan otomatis berbasis rating yang berpotensi menimbulkan noise serta belum diterapkannya validasi silang (*cross-*

DOI : https://doi.org/10.36341/rabit.v11i1.6930 *Corresponding Author* : Octa Dwiansyah

validation), namun temuan ini tetap memberikan dasar empiris bagi BPJS Kesehatan untuk melakukan evaluasi dan peningkatan kualitas layanan aplikasi Mobile JKN.

KESIMPULAN

Riset ini menganalisis sentimen ulasan pengguna aplikasi Mobile JKN dengan membandingkan kinerja algoritma Naïve Bayes, KNN, dan SVM yang dioptimalkan menggunakan SMOTE untuk menangani ketidakseimbangan data. Hasil penelitian menunjukkan bahwa penerapan SMOTE mampu meningkatkan kemampuan model dalam mengenali kelas minoritas tanpa menurunkan kinerja secara signifikan, sehingga menghasilkan klasifikasi yang lebih adil dan representatif.

Pada Naïve Bayes, akurasi menurun dari 93,56% menjadi 92,05% setelah SMOTE, namun recall kelas negatif meningkat dari 0,95 menjadi 0,97. KNN menunjukkan peningkatan paling signifikan, dengan akurasi naik dari 71,20% menjadi 87,96% dan F1-score kelas negatif meningkat dari 0,39 menjadi 0,86. Sementara itu, SVM mempertahankan performa tertinggi dan paling stabil dengan akurasi sekitar 93% dan F1-score pada kisaran 0,91–0,95. Perbandingan F1-score dan ROC-AUC juga menegaskan keunggulan SVM dengan nilai AUC sebesar 0,98, diikuti Naïve Bayes (0,97) dan KNN (0,93).

Secara keseluruhan, hasil penelitian membuktikan bahwa SMOTE efektif dalam memperbaiki distribusi kelas dan meningkatkan kinerja model, khususnya pada KNN, serta menunjukkan bahwa SVM merupakan algoritma paling unggul untuk analisis sentimen ulasan aplikasi Mobile JKN. Mayoritas ulasan pengguna yang tergolong positif juga mengindikasikan tingkat kepuasan pengguna yang relatif tinggi terhadap layanan aplikasi. Penelitian selanjutnya disarankan untuk mengeksplorasi pendekatan *deep learning* seperti LSTM dan IndoBERT, mengembangkan analisis sentimen berbasis aspek, serta menerapkan pelabelan manual atau semi-manual guna meningkatkan validitas hasil.

DAFTAR PUSTAKA

[1] Sriani, Suhardi, and L. S. Yardha, "Analisis Sentimen Pengguna Aplikasi Mobile Jkn Menggunakan Algoritma Naïve Bayes," 2024. [Online]. Available: http://jurnal.goretanpena.com/index.php/JSSR

[2] N. Aditiya and P. Setiaji, "Sistemasi: Jurnal Sistem Informasi Analisis Sentimen Kepuasan Masyarakat terhadap Aplikasi 'INFO BMKG' menggunakan Naive Bayes, SVM, dan KNN Sentiment Analysis of Public Satisfaction with the 'INFO BMKG' Application using Naive Bayes, SVM, and KNN," 2025. [Online]. Available: http://sistemasi.ftik.unisi.ac.id

[3] G. Septania Al-Husna, D. Asmarajati, I. Ahmad Ihsanuddin, R. Mahmudati, U. Sains Al-Qur, and R. Artikel, "Perbandingan Metode Naïve Bayes Dan Support Vector Machine Untuk Analisis Sentimen Pada Ulasan Pengguna Aplikasi Linkedin 1) Info Artikel Abstrak," vol. 3, no. 2, pp. 139–144, 2024, doi: 10.55123.

[4] R. Rojakul, S. Sumardianto, and A. Wibowo, "Analisis Sentimen Popularitas Capres dan Pilpres pada Media Sosial Twitter: Perbandingan Algoritma SVM, KNN, dan Naïve Bayes," *Techno.Com*, vol. 23, no. 2, pp. 362–375, May 2024, doi: 10.62411/tc.v23i2.10135.

[5] E. Indrayuni, A. Nurhadi, and D. A. Kristiyanti, "Implementasi Algoritma Naive Bayes, Support Vector Machine, dan K-Nearest Neighbors untuk Analisa Sentimen Aplikasi Halodoc," *Faktor*

Exacta, vol. 14, no. 2, p. 64, Aug. 2021, doi: 10.30998/faktorexacta.v14i2.9697.

[6] F. Suandi *et al.*, "Enhancing Sentiment Analysis Performance Using SMOTE and Majority Voting in Machine Learning Algorithms," 2024, pp. 126–138. doi: 10.2991/978-94-6463-620-8_10.

[7] Y. D. Nugroho H, F. Zakiyabarsi, and A. J. Paramita, "Implementasi Smote-Enn Dan Borderline Smote Terhadap Performa Lightgbm Pada Imbalanced Class," *Rabit : Jurnal Teknologi dan Sistem Informasi Univrab*, vol. 10, no. 1, pp. 51–59, Jan. 2025, doi: 10.36341/rabit.v10i1.5436.

[8] G. Tamami, W. A. Triyanto, and S. Muzid, "Sentiment Analysis Mobile JKN Reviews Using SMOTE Based LSTM," *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, vol. 19, no. 1, p. 13, Jan. 2025, doi: 10.22146/ijccs.101910.

[9] I. F. A. Mubarok, B. Huda, A. Hananto, T. Tukino, and H. Kabir, "Analisis User Sentiment Aplikasi Google Maps, Maps.Me Dan Waze Menggunakan Metode Support Vector Machine," *Rabit : Jurnal Teknologi dan Sistem Informasi Univrab*, vol. 8, no. 1, pp. 69–74, Jan. 2023, doi: 10.36341/rabit.v8i1.3020.

[10] M. Hardiyanti and M. K. Fajarlestari, "Sistemasi: Jurnal Sistem Informasi Optimasi Analisis Sentimen Komentar Penonton Wayang Digital dengan SMOTE dan Algoritma Naïve Bayes Optimizing Sentiment Analysis of Digital Wayang Viewer Comments using SMOTE and the Naïve Bayes Algorithm," 2025. [Online]. Available: http://sistemasi.ftik.unisi.ac.id

[11] B. A. Maulana, M. J. Fahmi, A. M. Imran, and N. Hidayati, "Analisis Sentimen Terhadap Aplikasi Pluang Menggunakan Algoritma Naive Bayes dan Support Vector Machine (SVM)," *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 4, no. 2, pp. 375–384, Feb. 2024, doi: 10.57152/malcom.v4i2.1206.

[12] A. I. Kamil, O. N. Pratiwi, and D. Witarsyah, "Analisis Sentimen dan Pemodelan Topik terhadap Aplikasi Pembelajaran Online pada Platform Google Play," *JIPI (Jurnal Ilmiah Penelitian dan Pembelajaran Informatika)*, vol. 10, no. 2, pp. 836–849, Mar. 2025, doi: 10.29100/jipi.v10i2.6023.

[13] M. Afrad, C. Febrianto, S. Wijayanto, and Y. Fathoni, "Edu Komputika Journal Sentiment Analysis of Visitor Reviews on Baturaden Tourist Attraction Using Machine Learning Methods," *Edu Komputika*, vol. 11, no. 1, 2024, [Online]. Available: https://journal.unnes.ac.id/journals/edukom/

[14] B. Rahmatullah, P. Budiyono, and A. S. Suwanda, "Sentimen Analisis Transportasi Online Menggunakan Algoritma Support Vector Machine, Naive Bayes Dan KNN," *Jurnal Ilmu Komputer JIK*, Dec. 2021, [Online]. Available: https://t.co/ZYbdHbWj5

[15] M. I. Abidin and E. W. Pamungkas, "Analisis Sentimen Terhadap Timnas Indonesia Di Piala Asia 2023 Dengan Model Transformer Berbahasa Indonesia," *Rabit : Jurnal Teknologi dan Sistem Informasi Univrab*, vol. 10, no. 2, pp. 482–496, Jul. 2025, doi: 10.36341/rabit.v10i2.6142.