Jurnal Penelitian Sistem Informasi
Volume 4, Nomor 3, Agustus 2026
e-ISSN: 2985-7759, p-ISSN: 2985-6310, Hal. 230-245
DOI: https://doi.org/10.54066/jpsi.v4i3.4537
Tersedia: https://jurnal.itbsemarang.ac.id/index.php/JPSI

Analisis Sentimen Pengguna Aplikasi Mobile JKN menggunakan Algoritma *Support Vector Machine* dan *Naive Bayes*

Muhamad Bahrul Irfan[1*], Herny Februariyanti[2]
[1-2] Program Studi Sistem Informasi, Universitas Stikubank Semarang, Indonesia
Email: muhamadbahrul0020@mhs.unisbank.ac.id[1], hernyfeb@edu.unisbank.ac.id[2]
**Penulis Korespondensi: muhamadbahrul0020@mhs.unisbank.ac.id*

Abstract*. The Mobile JKN application serves as the primary digital gateway developed by BPJS Kesehatan, enabling National Health Insurance participants to manage administrative needs and access health-related information remotely. Despite its widespread adoption, persistent user grievances—documented through Google Play Store reviews—signal opportunities for service refinement. This research harvested 20,000 user reviews via automated scraping (August 1–December 15, 2025) and retained 18,729 valid entries following a five-stage preprocessing pipeline encompassing cleaning, normalization, tokenization, stemming, and stopword elimination. Feature representation relied on TF-IDF vectorization, while training-set class imbalance was counteracted through SMOTE oversampling. A head-to-head evaluation pitted LinearSVC against Complement Naive Bayes across three sentiment polarities. LinearSVC emerged as the stronger classifier, registering 81.71% accuracy alongside a weighted F1-score of 0.84—surpassing its probabilistic counterpart at 79.85% accuracy and 0.83 weighted F1-score. Both architectures demonstrated robust positive-class detection (F1=0.92) yet faltered on neutral reviews, where overlapping lexical cues between praise and complaint eroded discriminative power. Wordcloud mapping further exposed recurring dissatisfaction markers ("susah", "sulit", "ribet") juxtaposed with appreciation signals ("bantu", "mudah", "bagus"), offering actionable intelligence for BPJS Kesehatan to target specific service pain points.*

Keywords*: Mobile JKN; Naive Bayes; Sentiment Analysis; SMOTE; Support Vector Machine*.

Abstrak. Aplikasi *Mobile* JKN berfungsi sebagai kanal digital utama yang dikembangkan BPJS Kesehatan untuk memfasilitasi peserta JKN dalam mengelola keperluan administratif dan memperoleh informasi kesehatan secara daring. Terlepas dari tingginya adopsi pengguna, beragam keluhan yang terekam pada ulasan Google Play Store mengisyaratkan perlunya peningkatan kualitas layanan. Penelitian ini menjaring 20.000 ulasan pengguna melalui *scraping* otomatis (1 Agustus–15 Desember 2025) dan mempertahankan 18.729 ulasan valid setelah melewati lima tahap *preprocessing*: *cleaning*, normalisasi, *tokenizing*, *stemming*, dan *stopword removal*. Representasi fitur menggunakan vektorisasi TF-IDF, sementara ketimpangan kelas pada data latih dinetralisasi melalui teknik SMOTE. Evaluasi komparatif mengadu LinearSVC melawan *Complement Naive Bayes* pada tiga polaritas sentimen. LinearSVC tampil sebagai pengklasifikasi yang lebih andal dengan akurasi 81,71% dan *weighted F1-score* 0,84—melampaui rivalnya yang mencatat akurasi 79,85% dan *weighted F1-score* 0,83. Kedua arsitektur menunjukkan kemampuan deteksi kelas positif yang kokoh (*F1-score* 0,92), namun mengalami penurunan performa pada kelas netral akibat tumpang tindih fitur leksikal antara ulasan bernada pujian dan keluhan. Pemetaan *wordcloud* turut mengungkap penanda ketidakpuasan yang berulang ("susah", "sulit", "ribet") berdampingan dengan sinyal apresiasi ("bantu", "mudah", "bagus"), menyediakan masukan konkret bagi BPJS Kesehatan untuk menyasar titik-titik layanan yang perlu diperbaiki.

Kata Kunci: Analisis Sentimen; *Mobile* JKN; *Naive Bayes*; SMOTE; *Support Vector Machine*.

1. LATAR BELAKANG

Kesehatan merupakan hak fundamental setiap warga negara yang dijamin konstitusi, sehingga pemerintah berkewajiban menyediakan sistem perlindungan kesehatan menyeluruh bagi seluruh lapisan masyarakat Indonesia (Ahmadi *et al*., 2025). Komitmen tersebut diwujudkan melalui program Jaminan Kesehatan Nasional (JKN), yakni skema asuransi sosial yang menanggung layanan kesehatan komprehensif mulai dari pencegahan hingga pemulihan (Hutabarat *et al*., 2025).

Naskah Masuk: 13 Mei 2026; Revisi: 15 Juni 2026; Diterima: 16 Juli 2026; Tersedia: 24 Juli 2026

Sebagai upaya memperluas jangkauan layanan kepada peserta, BPJS Kesehatan memperkenalkan aplikasi *Mobile* JKN yang resmi beroperasi pada 15 September 2017 (Sriani & Suhardi, 2024). Melalui aplikasi ini, peserta dapat menyelesaikan beragam urusan administratif secara digital—mencakup pengecekan status kepesertaan, transaksi pembayaran, registrasi layanan, sampai penyampaian keluhan—tanpa perlu mendatangi kantor cabang secara fisik (Yunizar *et al*., 2023; Putra *et al*., 2025).

Kendati demikian, *Mobile* JKN masih menuai beragam kritik dari penggunanya (Roiqoh *et al*., 2023). Ulasan di Google Play Store menjadi cermin nyata kepuasan dan keluhan pengguna, sehingga analisis sentimen terhadap ulasan tersebut menjadi instrumen strategis bagi pemerintah untuk mengidentifikasi aspek yang perlu diperbaiki dan meningkatkan kualitas layanan secara berkelanjutan.

Guna mengungkap polaritas opini pengguna, penelitian ini membandingkan dua algoritma klasifikasi—*Support Vector Machine* (SVM) dan *Naive Bayes*—terhadap ulasan *Mobile* JKN yang dikumpulkan dari Google Play Store guna mengelompokkannya berdasarkan polaritas sentimen: positif, negatif, ataupun netral. SVM bekerja berdasarkan prinsip *Structural Risk Minimization* untuk menemukan *hyperplane* pemisah antarkelas (Dasriani *et al*., 2025; Sarimole & Kudrat, 2024), sedangkan *Naive Bayes* mengklasifikasikan teks melalui pendekatan probabilistik berbasis Teorema Bayes (Yunizar *et al*., 2023). Secara spesifik, penelitian ini memiliki tiga sasaran: (1) mengklasifikasikan sentimen ulasan menggunakan SVM dan *Naive Bayes*, (2) membandingkan performa kedua algoritma berdasarkan metrik akurasi, *precision*, *recall*, serta *F1-score*, dan (3) memvisualisasikan hasil klasifikasi menggunakan *wordcloud*.

2. KAJIAN TEORITIS

Analisis sentimen merupakan pendekatan komputasional untuk mengidentifikasi dan menggolongkan nada opini suatu teks—apakah cenderung bernada positif, negatif, ataupun bersifat netral (Roiqoh *et al*., 2023). Teknik ini mentransformasi informasi tidak terstruktur menjadi data terstruktur sebagai bagian dari *text mining* (Nitami & Februariyanti, 2022), di mana klasifikasi bertugas mengelompokkan dokumen ke dalam kategori tertentu berdasarkan pembelajaran dari data berlabel (Nitami & Februariyanti, 2022). Data teks perlu melalui tahapan *preprocessing* terlebih dahulu sebelum dapat dianalisis oleh algoritma (Sari *et al*., 2025).

Support Vector Machine (SVM) termasuk dalam kategori algoritma pembelajaran mesin terawasi yang memiliki kapabilitas ganda—baik untuk keperluan klasifikasi maupun prediksi regresi (Dasriani *et al*., 2025), dengan prinsip kerja berbasis *Structural Risk Minimization* yang mengonstruksi *hyperplane* sebagai batas pemisah antarkelas (Sarimole & Kudrat, 2024). Algoritma ini dikenal tangguh terhadap overfitting dan menyediakan mekanisme kernel trick bagi data yang secara linier tidak dapat dipisahkan (Maulida *et al*., 2024; Ariaji *et al*., 2025; Aulia *et al*., 2025). Di sisi lain, *Naive Bayes* merupakan metode klasifikasi yang mengandalkan prinsip probabilistik Teorema Bayes dengan mengasumsikan bahwa setiap fitur berkontribusi secara independen (Yunizar *et al*., 2023; Ginting *et al*., 2025), yang unggul dalam efisiensi komputasi pada data berdimensi tinggi meskipun data latih terbatas (Fauzan & Prianto, 2024).

Berbagai studi terdahulu telah mengkaji kedua algoritma ini: Aulia *et al*. (2025) mencatatkan akurasi 95,50% dengan SVM pada ulasan *Get Contact*; Damayanti *et al*. (2025) memperoleh 94% dengan *Naive Bayes* pada ulasan *Mobile* JKN; Roiqoh *et al*. (2023) menemukan *Naive Bayes* (94,75%) mengungguli *Lexicon Based*; Sari *et al*. (2025) meraih 89,97% dengan SVM pada sentimen layanan BPJS; Rizki & Prihartono (2025) mendapat 84% dengan *Naive Bayes* pada ulasan rumah sakit; Sriani & Suhardi (2024) menunjukkan C4.5 mengungguli *Naive Bayes* pada ulasan *Mobile* JKN dari Twitter; Dasriani *et al*. (2025) memperoleh 81% dengan *Multiclass* SVM; Ariaji *et al*. (2025) menunjukkan SVM lebih unggul daripada *Random Forest*; Rahmasari *et al*. (2025) mencatatkan 92% dengan SVM pada ulasan *Glints*; dan Khoirunnisa & Februariyanti (2022) meraih 0,8565 dengan *Naive Bayes Classifiers* dan *Association* pada ulasan *Google Meet*.

Sebagai pembeda dari studi-studi tersebut, penelitian ini menghadapkan secara langsung dua varian spesifik—LinearSVC untuk SVM dan *Complement Naive Bayes*—pada 20.000 ulasan terkini aplikasi *Mobile* JKN dengan tiga kelas sentimen, disertai pembobotan TF-IDF serta teknik SMOTE untuk menangani ketidakseimbangan kelas yang muncul secara alami pada data ulasan.

3. METODE PENELITIAN

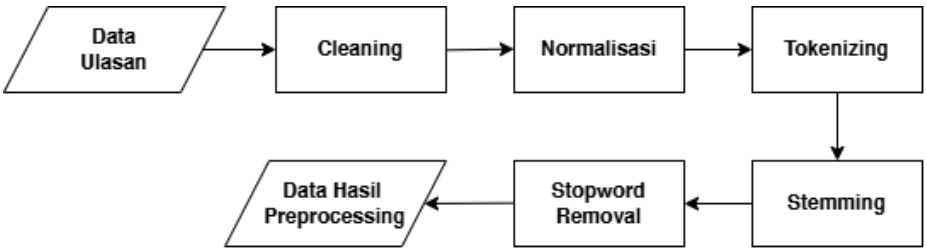
Objek dan Pengumpulan Data

Penelitian ini menjadikan ulasan pengguna aplikasi *Mobile* JKN di halaman Google Play Store sebagai objek kajian, mengingat platform tersebut merekam opini, pengalaman, dan penilaian pengguna secara organik (Putra *et al*., 2025). Pengumpulan data dilakukan melalui dua jalur: studi kepustakaan jurnal terkait SVM dan *Naive Bayes*, serta *scraping* otomatis

menggunakan bahasa pemrograman Python dengan pustaka *google-play-scraper*. Proses *scraping* diarahkan pada identitas unik aplikasi *Mobile* JKN, yaitu app.bpjs.mobile, dengan target sebanyak 20.000 ulasan pada rentang waktu 1 Agustus hingga 15 Desember 2025. Parameter sort=Sort.NEWEST diterapkan agar ulasan yang terjaring merupakan ulasan terkini yang merepresentasikan kondisi pembaruan aplikasi pada periode tersebut. Setiap entri ulasan memuat lima atribut: review_id sebagai pengenal unik, user_name, rating (skala 1–5), review_text, dan date. Seluruh data disimpan dalam format CSV dengan *encoding* utf-8-sig guna mengakomodasi karakter khusus termasuk *emoji* dan simbol Unicode.

Text Preprocessing

Text preprocessing merupakan rangkaian transformasi yang menjadikan data teks mentah lebih terstruktur agar siap diolah oleh algoritma *machine learning* (Aulia *et al*., 2025). Data ulasan mentah hasil scraping masih dipenuhi elemen-elemen pengganggu seperti URL, angka, emoji, simbol tanda baca, serta istilah non-standar yang harus dibersihkan sebelum pemrosesan lebih lanjut. *Preprocessing* pada penelitian ini menggunakan pustaka NLTK dan PySastrawi dan terdiri dari lima tahap sebagaimana ditunjukkan pada Gambar 1.



Gambar 1. Tahapan *text processing.*

Tahap pertama (*cleaning*) mengonversi teks ke huruf kecil, menghapus URL, angka, emoji, dan tanda baca. Tahap kedua (normalisasi) mengganti kata tidak baku dan singkatan berdasarkan kamus kamuskatabaku.xlsx, misalnya "bgt" menjadi "banget". Tahap ketiga (*tokenizing*) menguraikan teks menjadi unit kata individual melalui fungsi word_tokenize pada pustaka NLTK. Tahap keempat (*stemming*) mengembalikan kata berimbuhan ke bentuk dasar via pustaka Sastrawi (algoritma Nazief-Adriani), misalnya "antrian" menjadi "antri". Tahap kelima (*stopword removal*) menghapus kata tidak bermakna sentimen berdasarkan stopwordID.xlsx. Contoh transformasi setiap tahap disajikan pada Tabel 1.

Tabel 1. Contoh transformasi teks pada tahapan *preprocessing.*

Tahapan	Hasil Teks
Teks mentah (input)	Aduh parah!!! saya kasih bintang 2 dulu. Karena ini keluar terus saya mau ambil Antrian tapi tidak bisa masuk APLIKASI 😭😭#kecewa
Cleaning	aduh parah saya kasih bintang dulu karena ini keluar terus saya mau ambil antrian tapi tidak bisa masuk aplikasi kecewa
Normalisasi	aduh parah saya kasih bintang dulu karena ini keluar terus saya mau ambil antrian tapi tidak bisa masuk aplikasi kecewa
Tokenizing	['aduh', 'parah', 'saya', 'kasih', 'bintang', 'dulu', 'karena', 'ini', 'keluar', 'terus', 'saya', 'mau', 'ambil', 'antrian', 'tapi', 'tidak', 'bisa', 'masuk', 'aplikasi', 'kecewa']
Stemming	['aduh', 'parah', 'saya', 'kasih', 'bintang', 'dulu', 'karena', 'ini', 'luar', 'terus', 'saya', 'mau', 'ambil', 'antri', 'tapi', 'tidak', 'bisa', 'masuk', 'aplikasi', 'kecewa']
Stopword removal	aduh parah kasih bintang luar ambil antri tidak bisa masuk aplikasi kecewa

Pelabelan Data

Pemberian label sentimen menerapkan pendekatan *rating-based labeling* yang mengonversi skala bintang pengguna menjadi tiga kelas: ulasan dengan *rating* 4–5 dikategorikan sebagai sentimen positif karena merepresentasikan kepuasan dan apresiasi, *rating* 3 dikategorikan sebagai sentimen netral karena mencerminkan opini ambigu yang tidak secara tegas berpihak, dan *rating* 1–2 dikategorikan sebagai sentimen negatif karena mengindikasikan keluhan atau pengalaman buruk. Skema ini memastikan uniformitas label tanpa memerlukan anotasi manual. Dari 18.729 ulasan valid, distribusi kelas yang dihasilkan bersifat timpang: kelas positif mendominasi dengan 11.686 ulasan (62,40%), diikuti kelas negatif sebanyak 6.299 ulasan (33,63%), dan kelas netral yang hanya berjumlah 744 ulasan (3,97%)—ketimpangan inilah yang mendasari penerapan teknik SMOTE pada tahap selanjutnya.

Pembobotan TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) merupakan teknik pembobotan yang mengonversi teks ulasan ke dalam bentuk vektor numerik dan secara bersamaan mengkuantifikasi seberapa signifikan suatu kata dalam konteks satu dokumen dibandingkan keseluruhan kumpulan dokumen (Dasriani *et al*., 2025). Elemen *Term Frequency* (TF) menghitung intensitas kehadiran suatu kata pada sebuah dokumen, sedangkan elemen *Inverse Document Frequency* (IDF) merefleksikan tingkat eksklusivitas kata tersebut dengan mempertimbangkan rasio dokumen yang mengandungnya terhadap total koleksi (Ariaji *et al*., 2025). Besaran bobot TF-IDF dikalkulasi menggunakan Persamaan (1) dan (2).

$$W_{d,k} = TF_{d,k} \times IDF_k \quad \text{(i)}$$

$$IDF_k = log\left(\frac{N}{DF_k}\right) \quad \text{(ii)}$$

Pada formulasi tersebut, Wd,k merepresentasikan bobot kata ke-k dalam ulasan ke-d, TFd,k menyatakan frekuensi kemunculan kata ke-k pada ulasan ke-d, IDFk menunjukkan nilai *inverse document frequency* kata ke-k, N adalah volume total ulasan dalam *dataset*, dan DFk merupakan jumlah ulasan yang memuat kata ke-k.

SMOTE

Ketidakseimbangan kelas (*class imbalance*) pada data ulasan—dominasi kelas positif dan minimnya data netral—berpotensi membuat model bias terhadap kelas mayoritas (Ariaji *et al*., 2025). Penelitian ini mengatasi masalah ini dengan SMOTE (*Synthetic Minority Over-sampling Technique*), yang berbeda dari *random over-sampling* karena membangkitkan sampel sintetis baru di ruang fitur—bukan sekadar menduplikasi data. SMOTE bekerja tiga langkah: (1) mencari *k-nearest neighbors* setiap titik minoritas via jarak Euclidean Persamaan (3), (2) memilih tetangga secara acak, (3) membentuk sampel baru via interpolasi linier Persamaan (4).

$$d(A,B) = \sqrt{\sum_{j=1}^{m}(A_j - B_j)^2} \quad \text{(iii)}$$

$$x_{new} = x_i + \lambda \times (x_{zi} - x_i) \quad \text{(iv)}$$

Pada Persamaan (3), d(A,B) adalah jarak Euclidean antara dua titik sampel A dan B pada ruang fitur berdimensi m. Pada Persamaan (4), xnew adalah titik koordinat fitur (bobot TF-IDF) baru hasil sintetis, xi adalah titik sampel data minoritas asli yang sedang diproses, xzi adalah titik sampel tetangga terdekat dari xi yang dipilih secara acak, dan λ adalah angka acak dengan rentang $0 \leq \lambda \leq 1$. Sebelum SMOTE diterapkan, *dataset* dipartisi menggunakan fungsi train_test_split dengan rasio 80:20 (80% data latih, 20% data uji), parameter stratify=y untuk mempertahankan proporsi kelas asli pada kedua partisi, dan random_state=42 demi reprodusibilitas. Dengan konfigurasi ini, data latih berjumlah 14.983 ulasan dan data uji 3.746 ulasan. Fungsi fit_resample dari SMOTE kemudian hanya dikenakan pada porsi data latih, sehingga data uji tetap murni mencerminkan distribusi alami ulasan Google Play Store. Pendekatan ini krusial untuk menghindari kebocoran data (*data leakage*) yang dapat memicu bias optimis pada evaluasi model, sekaligus memastikan data uji tetap murni

merepresentasikan distribusi ulasan Play Store yang tidak seimbang secara alami. Parameter random state=42 digunakan agar hasil pengacakan konsisten setiap kali program dijalankan ulang.

Klasifikasi Support Vector Machine (SVM)

LinearSVC dari pustaka *scikit-learn* (versi 1.3) dipilih karena efisien pada matriks TF-IDF berdimensi tinggi. Model dikonfigurasi dengan parameter class_weight='balanced' untuk memberikan penalti proporsional pada kelas berfrekuensi rendah, loss='squared_hinge' sebagai fungsi kerugian *default*, dan max_iter=1000 sebagai batas iterasi konvergensi. Fungsi keputusan SVM pada Persamaan (5) mencari *hyperplane* optimal Persamaan (6) yang memaksimalkan margin antarkelas. Karena terdapat tiga kelas, LinearSVC mengadopsi strategi *One-vs-Rest* (OvR) yang membangun tiga sub-model biner. Skor keputusan tiap sub-model dihitung pada Persamaan (7), dan kelas dengan skor tertinggi dijadikan prediksi akhir. Parameter class_weight='balanced' diterapkan sebagai optimasi tambahan untuk kelas berfrekuensi rendah.

$$f(x) = w^T x + b \quad \text{(v)}$$

dengan f(x) = nilai prediksi; w^T = vektor bobot penentu arah *hyperplane*; x = vektor fitur; b = bias penggeser. *Hyperplane* pemisah optimal dirumuskan pada Persamaan (6).

$$w \cdot x + b = 0 \quad \text{(vi)}$$

Dengan strategi OvR, LinearSVC membangun sub-model: negatif vs (netral+positif), netral vs (negatif+positif), dan positif vs (negatif+netral). Ulasan diklasifikasikan ke kelas dengan skor fungsi linier Persamaan (7) tertinggi.

$$f(x) = (w_1 x_1) + (w_2 x_2) + b \quad \text{(vii)}$$

Sebagai ilustrasi, ulasan uji "Login JKN susah" yang setelah TF-IDF hanya memuat kata bermakna sentimen "susah" dengan bobot $x_1 = 0{,}60$ (dan $x_2 = 0{,}00$ untuk kata "bagus" yang tidak muncul) menghasilkan skor keputusan f(x) sub-model negatif = (2,5 × 0,60) + (−1,2 × 0,00) + (−0,1) = 1,4, sub-model netral = −0,6, dan sub-model positif = −1,4. Karena skor terbesar diraih sub-model negatif, ulasan tersebut diklasifikasikan ke dalam kelas sentimen negatif.

Klasifikasi Naive Bayes

Complement Naive Bayes (CNB) dipilih karena mengatasi kelemahan *Naive Bayes* standar pada data tidak seimbang, dengan menghitung probabilitas kata terhadap kelas pelengkapnya sehingga model tidak bias ke kelas mayoritas. Landasan probabilistik CNB

adalah Teorema Bayes pada Persamaan (8), dengan P(c|d) = probabilitas posterior ulasan d masuk kelas c; P(d|c) = likelihood fitur pada kelas c; P(c) = prior kelas c; P(d) = evidensi. Bobot komplemen dihitung pada Persamaan (9) dan keputusan akhir pada Persamaan (10).

$$P(c|d) = \frac{P(d|c) \times P(c)}{P(d)} \quad \text{(viii)}$$

$$w_{ci} = log\left(\frac{N_{\sim c,i} + \alpha}{\sum_j N_{\sim c,j} + \alpha}\right) \quad \text{(ix)}$$

$$h(d) = argmin_c \sum_i x_i \cdot w_{ci} \quad \text{(x)}$$

Dengan wci = bobot fitur kata i terhadap kelas komplemen c; N~c,i = total TF-IDF kata i di luar kelas c; α = *Laplace smoothing* (1,0); ΣjN~c,j = total TF-IDF kosakata di luar kelas c; xi = bobot TF-IDF kata ke-i pada dokumen uji. Skor penjumlahan minimum menandakan kecocokan tertinggi pada kelas target itu sendiri. Sebagai ilustrasi, pada ulasan uji "Login JKN susah" dengan bobot kata "susah" x_1 = 0,60, skor komplemen negatif = (0,60 × 1,0) = 0,60, netral = (0,60 × 3,0) = 1,80, dan positif = (0,60 × 4,5) = 2,70, sehingga ulasan diklasifikasikan sebagai sentimen negatif karena skor komplemennya paling minimum. Implementasi menggunakan ComplementNB dari pustaka *scikit-learn* dengan parameter alpha=1,0 sebagai nilai *Laplace smoothing* dan norm=False, yang dilatih pada data latih hasil SMOTE identik dengan SVM guna menjamin kesetaraan kondisi eksperimen.

Pengujian dan Evaluasi Model

Kinerja model dievaluasi pada data uji yang sama sekali tidak terpapar selama fase pelatihan, menggunakan empat metrik utama: akurasi (proporsi prediksi tepat secara keseluruhan), *precision* (ketepatan prediksi pada masing-masing kelas), *recall* (cakupan model dalam mendeteksi seluruh sampel suatu kelas), dan *F1-score* (keseimbangan harmonis antara *precision* dan *recall*). Sebaran hasil prediksi divisualisasikan melalui *confusion matrix* (Tabel 2), di mana elemen diagonal utama (E11, E22, E33) menunjukkan prediksi tepat dan elemen di luarnya menunjukkan kesalahan klasifikasi. Hasil kedua algoritma dibandingkan untuk menentukan model terbaik.

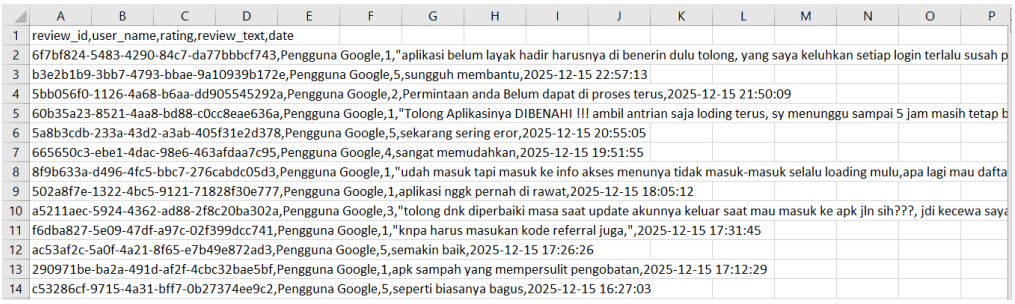
Tabel 2. Skema *confusion matrix* klasifikasi tiga kelas.

	Prediksi Negatif	**Prediksi Netral**	**Prediksi Positif**
Aktual Negatif	E11	E12	E13
Aktual Netral	E21	E22	E23
Aktual Positif	E31	E32	E33

4. HASIL DAN PEMBAHASAN

Hasil Pengumpulan Data dan Preprocessing

Pengumpulan data ulasan pengguna aplikasi *Mobile* JKN dilaksanakan secara otomatis (*automated scraping*) melalui Google Play Store dan berhasil menjaring 20.000 baris ulasan sesuai kuota yang ditentukan. Data mentah hasil penarikan kemudian diorganisasi ke dalam struktur *array* dan diekspor ke berkas scraper_ulasan_jkn.csv. Cuplikan hasil *scraping* ditunjukkan pada Gambar 2.



	A
1	review_id,user_name,rating,review_text,date
2	6f7bf824-5483-4290-84c7-da77bbbcf743,Pengguna Google,1,"aplikasi belum layak hadir harusnya di benerin dulu tolong, yang saya keluhkan setiap login terlalu susah p
3	b3e2b1b9-3bb7-4793-bbae-9a10939b172e,Pengguna Google,5,sungguh membantu,2025-12-15 22:57:13
4	5bb056f0-1126-4a68-b6aa-dd905545292a,Pengguna Google,2,Permintaan anda Belum dapat di proses terus,2025-12-15 21:50:09
5	60b35a23-8521-4aa8-bd88-c0cc8eae636a,Pengguna Google,1,"Tolong Aplikasinya DIBENAHI !!! ambil antrian saja loding terus, sy menunggu sampai 5 jam masih tetap b
6	5a8b3cdb-233a-43d2-a3ab-405f31e2d378,Pengguna Google,5,sekarang sering eror,2025-12-15 20:55:05
7	665650c3-ebe1-4dac-98e6-463afdaa7c95,Pengguna Google,4,sangat memudahkan,2025-12-15 19:51:55
8	8f9b633a-d496-4fc5-bbc7-276cabdc05d3,Pengguna Google,1,"udah masuk tapi masuk ke info akses menunya tidak masuk-masuk selalu loading mulu,apa lagi mau dafta
9	502a8f7e-1322-4bc5-9121-71828f30e777,Pengguna Google,1,aplikasi nggk pernah di rawat,2025-12-15 18:05:12
10	a5211aec-5924-4362-ad88-2f8c20ba302a,Pengguna Google,3,"tolong dnk diperbaiki masa saat update akunnya keluar saat mau masuk ke apk jln sih???, jdi kecewa saya
11	f6dba827-5e09-47df-a97c-02f399dcc741,Pengguna Google,1,"knpa harus masukan kode referral juga,",2025-12-15 17:31:45
12	ac53af2c-5a0f-4a21-8f65-e7b49e872ad3,Pengguna Google,5,semakin baik,2025-12-15 17:26:26
13	290971be-ba2a-491d-af2f-4cbc32bae5bf,Pengguna Google,1,apk sampah yang mempersulit pengobatan,2025-12-15 17:12:29
14	c53286cf-9715-4a31-bff7-0b27374ee9c2,Pengguna Google,5,seperti biasanya bagus,2025-12-15 16:27:03

Gambar 2. Hasil *scraping* data ulasan aplikasi Mobile JKN.

Keseluruhan ulasan melewati lima tahap *preprocessing* secara berurutan. Tahap *cleaning* mengeliminasi URL, angka, *emoji*, tanda baca, dan spasi berlebih, serta menyeragamkan huruf menjadi huruf kecil. Tahap normalisasi menyelaraskan kata tidak baku ke bentuk baku berdasarkan kamus, tahap *tokenizing* mengurai kalimat menjadi satuan token kata, tahap *stemming* menyederhanakan kata berimbuhan ke akar katanya (sebagai contoh, "menggunakan", "digunakan", dan "pengguna" sama-sama direduksi menjadi "guna"), dan tahap *stopword removal* menyaring kata-kata fungsional yang tidak berkontribusi pada makna sentimen. Pasca eliminasi data kosong dan duplikat, tersisa 18.729 ulasan valid untuk dianalisis.

Hasil Pelabelan Data

Pelabelan otomatis berdasarkan *rating* menghasilkan distribusi kelas sentimen sebagaimana ditunjukkan pada Gambar 3. Dari 18.729 ulasan valid, kelas positif mendominasi dengan 11.686 ulasan (62,40%), diikuti kelas negatif sebanyak 6.299 ulasan (33,63%), dan kelas netral hanya 744 ulasan (3,97%). Ketidakseimbangan kelas yang signifikan ini, terutama minimnya data kelas netral, menjadi dasar pertimbangan penerapan teknik SMOTE pada tahap berikutnya.

```
Distribusi Sentimen Berdasarkan Rating:
label_sentimen
positif    11686
negatif     6299
netral       744
Name: count, dtype: int64

Sampel Hasil Pelabelan:
   rating label_sentimen                                hasil_preprocessing
0       1        negatif              layak hadir benerin keluh susah lupa
1       5        positif                                   sungguh bantu
2       2        negatif                                          proses
3       1        negatif  benah antri tunggu wifi stabil susah cuman ber...
4       5        positif                                            eror
```

Gambar 3. Distribusi sentimen hasil pelabelan berbasis *rating.*

Hasil Pembobotan TF-IDF dan Penerapan SMOTE

Pembobotan TF-IDF menggunakan TfidfVectorizer (max_features=10.000, *unigram*) menghasilkan matriks berukuran 18.729 × 7.543. Sepuluh kata dengan bobot tertinggi ditampilkan pada Gambar 4, di mana kata "layak" dan "hadir" memiliki nilai IDF tertinggi yang menandakan keunikannya dalam koleksi dokumen. Matriks bobot tersebut kemudian dibagi secara *stratified* menjadi 80% data latih dan 20% data uji untuk mempertahankan proporsi kelas.

Karena distribusi data latih masih timpang—9.349 sampel positif, 5.039 negatif, dan hanya 595 netral (total 14.983)—maka teknik SMOTE diterapkan khusus pada porsi data latih. Setelah SMOTE, ketiga kelas menjadi seimbang dengan masing-masing 9.349 sampel (total 28.047), sedangkan data uji tetap sebanyak 3.746 ulasan guna menghindari kebocoran informasi.

	term	tf	idf	tf_idf
0	layak	1	7.891918	7.891918
1	hadir	1	8.739216	8.739216
2	benerin	1	5.561162	5.561162
3	keluh	1	6.076628	6.076628
4	susah	1	2.532640	2.532640
5	lupa	1	3.864019	3.864019
6	sungguh	1	6.793306	6.793306
7	bantu	1	1.875413	1.875413
8	proses	1	4.213811	4.213811
9	benah	1	5.966627	5.966627

```
Distribusi Kelas Latih SEBELUM SMOTE:
label_sentimen
positif    9349
negatif    5039
netral      595
Name: count, dtype: int64

Distribusi Kelas Latih SESUDAH SMOTE (Semua seimbang):
label_sentimen
positif    9349
negatif    9349
netral     9349
Name: count, dtype: int64
```

Gambar 4. Perhitungan TF-IDF dan distribusi kelas data latih sebelum dan sesudah SMOTE.

Hasil Klasifikasi *Support Vector Machine* (SVM)

Model SVM dikonfigurasi menggunakan LinearSVC dengan parameter classweight=balanced, dilatih pada data latih yang telah melalui SMOTE, dan diuji pada data uji yang sama sekali tidak terlibat dalam pelatihan. Gambar 5 menyajikan hasil evaluasi beserta *confusion matrix* model ini. SVM mencatatkan akurasi 81,71%, yang mengindikasikan bahwa empat dari lima ulasan berhasil diklasifikasikan dengan tepat. Pada kelas positif, model tampil dominan dengan *precision* 0,96 dan *recall* 0,89, sementara pada kelas negatif model tetap

memadai dengan *precision* 0,79 dan *recall* 0,74. Sebaliknya, performa kelas netral masih kurang optimal dengan *F1-score* 0,15, disebabkan oleh pola linguistik ulasan netral yang tumpang tindih dengan kelas lain. Rincian *confusion matrix* menunjukkan SVM mengidentifikasi 938 ulasan negatif, 38 ulasan netral, dan 2.085 ulasan positif secara tepat, dengan kesalahan terbesar berupa 249 ulasan negatif yang salah masuk ke kelas netral.

```
================ SVM + SMOTE ========================
Accuracy: 0.8171382808328884
              precision    recall  f1-score   support

     negatif       0.79      0.74      0.76      1260
      netral       0.10      0.26      0.15       149
     positif       0.96      0.89      0.92      2337

    accuracy                           0.82      3746
   macro avg       0.61      0.63      0.61      3746
weighted avg       0.87      0.82      0.84      3746

Confusion Matrix:
[[ 938  249   73]
 [  91   38   20]
 [ 165   87 2085]]
```

Gambar 5. Hasil evaluasi dan *confusion matrix* model SVM.

Hasil Klasifikasi *Naïve Bayes*

Complement Naive Bayes dibangun menggunakan set data latih yang serupa serta dievaluasi terhadap set data uji yang sama persis dengan SVM, menjamin objektivitas perbandingan kedua model. Gambar 6 menampilkan hasil evaluasi beserta *confusion matrix* model ini. CNB mencatatkan akurasi 79,85%, dengan performa kelas positif yang cukup kompetitif—*precision* 0,94 dan *recall* 0,91. Pada kelas negatif, *precision* mencapai 0,83 namun *recall* hanya 0,65, mengindikasikan bahwa model cukup kerap salah menempatkan ulasan negatif ke kelas lain. *Confusion matrix* menunjukkan 813 ulasan negatif, 58 ulasan netral, serta 2.120 ulasan positif terprediksi secara akurat, dengan kesalahan terbesar berupa 344 ulasan negatif yang terprediksi sebagai netral—angka yang lebih besar dibandingkan SVM yang hanya 249 ulasan.

```
================ COMPLEMENT NAIVE BAYES ================
Accuracy: 0.7984516817939135
              precision    recall  f1-score   support

     negatif       0.83      0.65      0.73      1260
      netral       0.11      0.39      0.17       149
     positif       0.94      0.91      0.92      2337

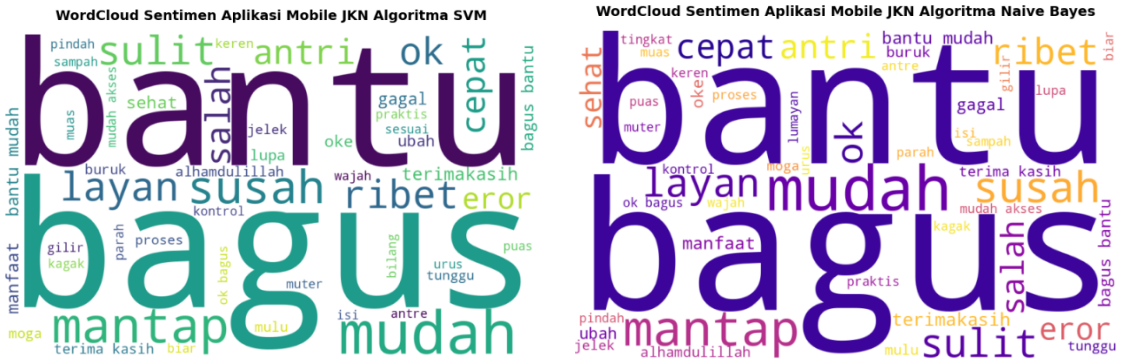
    accuracy                           0.80      3746
   macro avg       0.63      0.65      0.61      3746
weighted avg       0.87      0.80      0.83      3746

Confusion Matrix:
[[ 813  344  103]
 [  63   58   28]
 [ 104  113 2120]]
```

Gambar 6. Hasil evaluasi dan *confusion matrix* model *Complement Naive Bayes.*

Visualisasi *WordCloud*

Representasi *wordcloud* berfungsi menampilkan kata-kata dengan frekuensi tertinggi pada tiap kelas sentimen sesuai hasil prediksi masing-masing model, di mana dimensi visual suatu kata mencerminkan tingginya frekuensi kemunculan kata tersebut. Visualisasi dibangun dari teks ulasan data uji yang berhasil diklasifikasikan secara benar (*correct predictions*) oleh tiap model, sehingga kata yang tampil benar-benar mencerminkan performa riil algoritma, bukan sekadar seluruh kata dari data mentah. *Wordcloud* hasil prediksi model SVM dan *Naive Bayes* untuk ketiga kelas sentimen ditunjukkan pada Gambar 7.



Gambar 7. WordCloud hasil prediksi SVM (kiri) dan Naive Bayes (kanan) per kelas sentiment.

Pada kelas negatif, kata yang mendominasi antara lain "susah", "sulit", "ribet", "salah", "eror", "antri", dan "gagal", yang mencerminkan keluhan utama pengguna terhadap permasalahan teknis aplikasi seperti kegagalan sistem antrean dan kesulitan penggunaan aplikasi. Pada kelas positif, kata yang mendominasi antara lain "bantu", "mudah", "bagus", "mantap", "terimakasih", "manfaat", dan "cepat", yang mencerminkan kepuasan pengguna terhadap kemudahan dan manfaat layanan. Sementara itu, kelas netral menampilkan campuran kata positif dan negatif seperti "mudah", "suka", "susah", "eror", dan "ribet", yang menjelaskan mengapa kelas ini paling sulit diklasifikasikan karena memiliki kemiripan leksikal dengan kedua kelas lainnya. Secara keseluruhan pola *wordcloud* kedua model konsisten; perbedaan utama terletak pada komposisi kelas netral, di mana *Naive Bayes* cenderung mengklasifikasikan lebih banyak ulasan sebagai netral dibandingkan SVM, sejalan dengan nilai *recall* netral *Naive Bayes* yang lebih tinggi (0,39 berbanding 0,26).

Perbandingan Kinerja SVM dan Naïve Bayes

Kedua algoritma dibandingkan dalam skenario eksperimen yang sepenuhnya seragam—dataset yang sama telah melewati *preprocessing*, pelabelan, pembobotan TF-IDF, dan penyeimbangan SMOTE—lalu dievaluasi terhadap data uji yang identik. Rincian hasil perbandingan tercantum pada Tabel 3 dan Tabel 4.

Tabel 3. Perbandingan hasil evaluasi SVM dan *Naive Bayes.*

Metrik Evaluasi	SVM	Naive Bayes	Unggul
Akurasi	81,71%	79,85%	SVM
Precision Macro Avg	0,61	0,63	Naive Bayes
Recall Macro Avg	0,63	0,65	Naive Bayes
F1-Score Macro Avg	0,61	0,61	Seri
Precision Weighted Avg	0,87	0,87	Seri
Recall Weighted Avg	0,82	0,80	SVM
F1-Score Weighted Avg	0,84	0,83	SVM

Tabel 4. Perbandingan *F1-score* per kelas SVM dan *Naive Bayes.*

Kelas Sentimen	F1-Score SVM	F1-Score Naive Bayes	Unggul
Negatif	0,76	0,73	SVM
Netral	0,15	0,17	Naive Bayes
Positif	0,92	0,92	Seri

Berdasarkan Tabel 3, algoritma SVM memberikan performa keseluruhan yang lebih baik dibandingkan *Naive Bayes* dengan keunggulan pada akurasi (81,71% berbanding 79,85%), *recall weighted average* (0,82 berbanding 0,80), dan *F1-score weighted average* (0,84 berbanding 0,83), sedangkan *Naive Bayes* sedikit lebih baik pada *precision* dan *recall macro average*. Ditinjau per kelas pada Tabel 4, SVM lebih unggul dalam mengklasifikasikan sentimen negatif dengan *F1-score* 0,76 dibandingkan *Naive Bayes* yang hanya 0,73. Untuk kelas positif, kedua model menghasilkan *F1-score* identik sebesar 0,92, menunjukkan keduanya sama-sama andal dalam mengenali pola ulasan positif. Kontras yang mencolok terjadi pada kelas netral: meskipun *Naive Bayes* mencatat *recall* lebih tinggi (0,39 berbanding 0,26) yang berarti mampu menangkap lebih banyak ulasan netral, nilai *precision*-nya sangat rendah (0,11 berbanding 0,10 milik SVM), sehingga *F1-score* kedua model sama-sama terpuruk di angka 0,17 dan 0,15. Kesenjangan tajam antara performa kelas positif (*F1-score* 0,92) dan kelas netral (*F1-score* $\leq$ 0,17) ini mengindikasikan bahwa tantangan utama bukan terletak pada algoritma, melainkan pada sifat intrinsik data netral itu sendiri.

Rendahnya performa kedua model pada kelas netral berakar pada karakteristik linguistik yang khas dari ulasan ber-*rating* 3 bintang. Pengguna pada segmen ini cenderung menyusun ulasan dengan struktur campuran—misalnya memuat pujian terhadap satu aspek ("mudah mendaftar") yang langsung disandingkan dengan keluhan pada aspek lain ("tetapi sering *error* saat *login*")—sehingga fitur kata yang dihasilkan TF-IDF tumpang tindih secara substansial dengan kosakata kelas positif maupun negatif. Hal ini terkonfirmasi melalui visualisasi *wordcloud* kelas netral yang memuat kata-kata seperti "mudah" dan "suka" (tipikal positif) berdampingan dengan "susah" dan "eror" (tipikal negatif), menciptakan ruang fitur yang sulit dipisahkan oleh *hyperplane* SVM maupun batas keputusan probabilistik *Naive Bayes*. Meskipun SMOTE berhasil menyeimbangkan kuantitas sampel dari 595 menjadi 9.349 pada data latih, teknik ini hanya melakukan interpolasi pada ruang fitur yang sudah ada tanpa mampu menciptakan fitur diskriminatif baru yang membedakan pola netral dari kedua kelas lainnya. Minimnya jumlah data netral asli (3,97% dari total *dataset*) turut membatasi variasi pola linguistik yang dapat dipelajari model. Pola ini konsisten dengan laporan Roiqoh *et al*. (2023) dan Dasriani *et al*. (2025) yang juga melaporkan performa kelas netral yang lebih rendah dibandingkan kelas positif dan negatif pada klasifikasi sentimen tiga kelas. Nilai akurasi penelitian ini juga sebanding dengan Dasriani *et al*. (2025) yang memperoleh akurasi 81% menggunakan *Multiclass* SVM pada data sentimen program JKN. Secara keseluruhan, algoritma SVM dengan konfigurasi LinearSVC yang dikombinasikan dengan TF-IDF dan SMOTE lebih direkomendasikan untuk tugas analisis sentimen ulasan aplikasi *Mobile* JKN, mengingat akurasi 81,71% dan *weighted F1-score* 0,84 yang lebih tinggi dibandingkan *Complement Naive Bayes* dengan akurasi 79,85% dan *weighted F1-score* 0,83.

5. KESIMPULAN DAN SARAN

Studi ini menguji kemampuan dua algoritma—SVM dan *Naive Bayes*—dalam mengelompokkan 18.729 ulasan valid aplikasi *Mobile* JKN ke dalam tiga polaritas sentimen, dengan TF-IDF sebagai skema representasi fitur dan SMOTE sebagai penyeimbang kelas pada data latih. Eksperimen membuktikan bahwa LinearSVC mencatat performa superior atas *Complement Naive Bayes*, dengan selisih akurasi 81,71% berbanding 79,85% serta *weighted F1-score* 0,84 melawan 0,83. Kedua arsitektur sama-sama andal mengidentifikasi sentimen positif (*F1-score* 0,92), tetapi masih terkendala pada kelas netral (*F1-score* masing-masing 0,15 dan 0,17) karena ulasan ber-*rating* menengah cenderung memuat campuran ungkapan pujian dan keluhan yang secara leksikal sulit dibedakan. Pemetaan *wordcloud* lebih lanjut mengekspos kata-kata penanda ketidakpuasan yang konsisten muncul ("susah", "sulit", "ribet")

berdampingan dengan penanda apresiasi ("bantu", "mudah", "bagus")—temuan yang dapat dimanfaatkan BPJS Kesehatan sebagai peta prioritas perbaikan layanan aplikasi *Mobile* JKN.

Bagi penelitian berikutnya, direkomendasikan untuk memperluas sumber data ke *platform* lain seperti App Store atau X demi menjaring variasi opini yang lebih luas dan memperkuat daya generalisasi model. Tahapan *preprocessing* dapat ditingkatkan melalui pengayaan kamus normalisasi, penambahan teknik *negation handling*, serta metode deteksi sarkasme untuk meminimalkan kesalahan penafsiran makna teks ulasan. Selain itu, penelitian berikutnya dapat menerapkan metode klasifikasi lain seperti *K-Nearest Neighbor*, *Random Forest*, atau algoritma *deep learning* guna memperoleh performa yang lebih luas dan akurat.

DAFTAR REFERENSI

Ahmadi, D. A., Annisa, R., Refiana, R., & Purba, S. H. (2025). Tantangan dan peluang penggunaan JKN di Indonesia. *VitaMedica: Jurnal Rumpun Kesehatan Umum*, *3*(1), 85–92. https://doi.org/10.62027/vitamedica.v3i1.258

Ariaji, T., Wahyuni, S. N., & Ikhsan, M. (2025). Perbandingan algoritma SVM dan RF pada analisis sentimen menggunakan pendekatan machine learning. *Journal Automation Computer Information System*, *5*(1), 80–92. https://doi.org/10.47134/jacis.v5i1.107

Aulia, N., Sari, S. N., & Wakhidah, N. (2025). Analisis sentimen aplikasi GetContact di App Store menggunakan metode *support vector machine*. *Jurnal Informatika: Jurnal Pengembangan IT*, *10*(1), 139–148. https://doi.org/10.30591/jpit.v10i1.8057

Damayanti, E., Rahaningsih, N., Dana, R. D., & Rohmat, C. L. (2025). Analisis sentimen pengguna aplikasi Mobile Jaminan Kesehatan Nasional di Play Store menggunakan metode *naive Bayes*. *INTEK: Jurnal Informatika dan Teknologi Informasi*, *8*(1), 1–12.

Dasriani, N. G. A., Pariandi, L. A. G., & Dharma, I. M. Y. (2025). Analisis sentimen program Jaminan Kesehatan Nasional menggunakan multiclass *support vector machine*. *BIOS: Jurnal Teknologi Informasi dan Rekayasa Komputer*, *6*(1), 20–30. https://doi.org/10.37148/bios.v6i1.136

Fauzan, M. N., & Prianto, C. (2024). Analisis sentimen keluhan pegawai dengan menggunakan machine learning. *MULTINETICS*, *10*(2), 166–173. https://doi.org/10.32722/multinetics.v10i2.6894

Ginting, S. B. F., Tarigan, E. N., Sihaloho, B., & Telaumbanua, J. (2025). Analisis sentimen opini publik terhadap rumah sakit pemerintah dan swasta di Indonesia menggunakan algoritma *naïve Bayes*. *Jurnal Teknik Informatika UNIKA Santo Thomas*, 105–110.

Hutabarat, H. P., Mawarni, D., & Gurning, F. P. (2025). Analisis pemanfaatan pelayanan Jaminan Kesehatan Nasional (JKN) di Indonesia: A literature review. *Jurnal Kolaboratif Sains*, *8*(7), 4298–4307.

Khoirunnisa, F., & Februariyanti, H. (2022). Analisis sentimen kualitas layanan Google Meet menggunakan *naïve Bayes classifiers* dan association. *semanTIK*, *8*(1), 35–44. https://doi.org/10.55679/semantik.v8i1.25120

Maulida, N., Suarna, N., & Prihartono, W. (2024). Analisis ulasan sentimen aplikasi Mobile JKN dengan algoritma *support vector machine* berbasis *particle swarm optimization*. *JATI (Jurnal Mahasiswa Teknik Informatika), 8*(2), 1651–1658. https://doi.org/10.36040/jati.v8i2.9105

Nitami, M. T., & Februariyanti, H. (2022). Analisis sentimen ulasan ekspedisi J&T Express menggunakan algoritma *naive Bayes*. *Jurnal Manajemen Informatika dan Sistem Informasi, 5*(1), 20–29.

Putra, I. E., Asriyanik, A., & Azzahra, F. F. (2025). Pemanfaatan multinomial *naive Bayes* untuk analisis sentimen ulasan aplikasi Mobile JKN. *JATI (Jurnal Mahasiswa Teknik Informatika), 9*(2), 3283–3291. https://doi.org/10.36040/jati.v9i2.13311

Rahmasari, F., Rahaningsih, N., Dana, R. D., & Rohmat, C. L. (2025). Optimasi analisis sentimen aplikasi Glints menggunakan algoritma *support vector machine* (SVM). *Jurnal Informatika dan Teknik Elektro Terapan, 13*(1). https://doi.org/10.23960/jitet.v13i1.5681

Rizki, A. F., & Prihartono, W. (2025). Analisis sentimen ulasan Google Maps Rumah Sakit Khalishah di Cirebon dengan algoritma *naive Bayes*. *Jurnal Informatika dan Teknik Elektro Terapan, 13*(2). https://doi.org/10.23960/jitet.v13i2.6309

Roiqoh, S., Zaman, B., & Kartono, K. (2023). Analisis sentimen berbasis aspek ulasan aplikasi Mobile JKN dengan *lexicon-based* dan *naïve Bayes*. *Jurnal Media Informatika Budidarma, 7*(3), 1582–1592. https://doi.org/10.30865/mib.v7i3.6194

Sari, R. A. P., Kacung, S., & Santoso, B. (2025). Analisis sentimen layanan kesehatan BPJS menggunakan metode *support vector machine*. *Jurnal Informatika Teknologi dan Sains (JINTEKS), 7*(2), 878–885. https://doi.org/10.51401/jinteks.v7i2.5797

Sarimole, F. M., & Kudrat, K. (2024). Analisis sentimen terhadap aplikasi Satu Sehat pada Twitter menggunakan algoritma *naive Bayes* dan *support vector machine*. *Jurnal Sains dan Teknologi, 5*(3), 783–790. https://doi.org/10.55338/saintek.v5i3.2702

Sriani, S., & Suhardi, S. (2024). Analisis sentimen pengguna aplikasi Mobile JKN menggunakan algoritma *naive Bayes classifier* dan C4.5. *Journal of Science and Social Research, 7*(2), 555–563.

Yunizar, Z., Rusnani, R., Ardian, Z., Aidilof, H. A. K., & Maulana, O. M. M. (2023). Analisis sentimen pada Twitter terhadap aplikasi Mobile JKN menggunakan metode *naive Bayes classifier*. *Journal of Informatics and Computer Science, 9*(2), 103–111.